Diplomado en Ciencia de Datos

Geometra



GEOMETRA

GEOANALÍTICA Y DATOS DE UBICACIÓN

Aarón Eduardo Arceo Arjona

Recomendación de cafeterías en Mérida a partir de la afinidad de experiencia expresada en sus reseñas

Proyecto Integrador - Módulo 5 - Octubre 2026

Índice

1. Introducción **2**

2. Planteamiento del problema **2**

3. Descripción de los datos **3**
3.1. Fuentes oficiales: contexto del sector 4
3.2. Google Places: análisis exploratorio de los lugares 7
3.3. Reseñas de Google Maps: análisis exploratorio de las reseñas 8

4. Metodología **11**
4.1. Preparación de la referencia geográfica 12
4.2. Lectura del DENUE histórico 12
4.3. Obtención de lugares con Google Places 13
4.4. Extracción de reseñas 15
4.5. Análisis exploratorio e ingeniería de variables 15
4.6. Tratamiento de valores extremos y datos faltantes 16

5. Modelación **16**
5.1. Representación numérica de las reseñas 17
5.2. Función 1: de una cafetería a las más similares 17
5.3. Función 2: de las características a las cafeterías 20
5.4. Ponderación por número de reseñas 21
5.5. Vocabulario de características y atributos de las tarjetas 22
5.6. Sentimiento como modelo secundario 24
5.7. Evaluación y límites 24

6. Resolución del problema **25**

7. Interfaz de uso **26**
7.1. Arquitectura 26
7.2. Diseño 28
7.3. Guía de uso 28
7.4. Pruebas realizadas 29
7.5. Despliegue 30

8. Estrategia **33**
8.1. Descripción de usuarios 33
8.2. Accionables 33
8.3. Usabilidad del modelo 35
8.4. Alcance del negocio 36

9. Conclusiones **36**
9.1. Siguientes pasos 37

Referencias **38**

Anexos **40**

1. Introducción

El presente documento describe el proyecto desarrollado para la empresa ficticia **Geometra**, dedicada al análisis de datos con componente geográfico. Su actividad consiste en reunir información pública sobre los negocios de una zona (ubicaciones, atributos y reseñas de sus clientes) y procesarla para apoyar decisiones relacionadas con el territorio, como la elección de un lugar al cual asistir o la evaluación de una zona comercial.

El proyecto que aquí se presenta es el producto con el que Geometra muestra su tecnología: **Locus**, un recomendador de cafeterías para la ciudad de Mérida, Yucatán. Ofrece dos formas de uso. En la primera, la persona elige una cafetería que ya conoce y el sistema le devuelve las tres más parecidas. En la segunda, elige entre 20 características, como "ambiente tranquilo" o "para trabajar", y el sistema devuelve las diez cafeterías cuyas reseñas mejor las describen. En ambos casos el parecido se calcula con lo que escriben los clientes en sus reseñas y no con su calificación en estrellas, que en la ciudad es muy alta y distingue poco entre lugares.

Para lograrlo se reunieron 1,619 lugares con Google Places y 17,422 reseñas de Google Maps, se analizaron los datos y se convirtió el texto de las reseñas en vectores de números con un modelo de lenguaje preentrenado, sin entrenar ni ajustar ningún modelo, para medir el parecido entre cafeterías con la similitud del coseno. Para evaluar la búsqueda por características se revisó, en 16 consultas de prueba, cuántas de las diez cafeterías recomendadas tienen al menos dos reseñas que mencionan la característica buscada. En promedio, 6 de cada 10 cumplen esa condición, lo que equivale a una precisión de 0.61. Si las diez cafeterías se eligieran al azar, solo entre 1 y 2 la cumplirían (0.14), pues esa es la proporción de cafeterías que tienen reseñas sobre esas características. El resultado es más débil en las características que casi no se mencionan en las reseñas, como el wifi. La solución se puso a disposición mediante una aplicación web con mapa. El mismo desarrollo puede adaptarse más adelante a casos de uso entre empresas (B2B), por ejemplo, una cadena que evalúa dónde abrir una sucursal o una inmobiliaria que analiza el impacto comercial de una colonia; sin embargo, esos escenarios quedan fuera del alcance de este trabajo.

El documento se organiza de la siguiente manera. La Sección 2 plantea el problema y los objetivos; la Sección 3 describe los datos y su análisis exploratorio; la Sección 4, cómo se obtuvieron y prepararon; la Sección 5, el modelo y su evaluación; la Sección 6, cómo resuelve el problema; la Sección 7, la aplicación web; la Sección 8, la estrategia; y la Sección 9, las conclusiones.

2. Planteamiento del problema

En los últimos años la ciudad de Mérida ha registrado un aumento notable en su oferta de cafeterías, asociado al turismo, a la llegada de trabajadores de otras partes del país y al crecimiento de la cultura de café de especialidad. Como consecuencia, la oferta actual es amplia y heterogénea: dos cafeterías con una calificación promedio parecida pueden ofrecer experiencias muy distintas en cuanto a ambiente, atención, rango de precios, método de preparación o el uso principal que se le da al lugar (trabajar, convivir, desayunar o tomar fotografías).

Las plataformas de consulta más utilizadas, como Google Maps, permiten saber qué cafe-

terías existen y dónde se ubican, pero ordenan los resultados principalmente por popularidad y cercanía, no por la similitud entre la experiencia que ofrecen. Una persona que ya identificó una cafetería de su agrado no cuenta con una herramienta que le permita encontrar otras parecidas en los aspectos que le interesan. Esa información existe, pero se encuentra dispersa en una gran cantidad de reseñas en texto libre que no están organizadas para ese fin.

De lo anterior se desprende la pregunta que este proyecto busca responder: ¿cómo recomendar una cafetería a partir de otra que la persona usuaria ya conoce, o a partir de las características que busca, con base en lo que expresan sus clientes en las reseñas?

Para responderla, el proyecto se plantea los siguientes objetivos:

- **Construir el conjunto de reseñas.** Reunir la información de las cafeterías de Mérida a partir de fuentes públicas, como el Directorio Estadístico Nacional de Unidades Económicas (INEGI, s.f.) y Google Places (Google, s.f.), y sus reseñas de Google Maps, obtenidas mediante extracción con fines académicos, y depurarlas para su análisis.
- **Representar las reseñas de forma numérica.** Convertir cada reseña en un vector mediante modelos de *embeddings* de oraciones (Reimers y Gurevych, 2019), con el fin de obtener una representación cuantitativa de la experiencia asociada a cada cafetería.
- **Medir la similitud.** Calcular la similitud entre cafeterías con la medida de coseno, de modo que, dada una cafetería, se puedan identificar las más parecidas por lo que dicen sus clientes.
- **Permitir la búsqueda por características.** Devolver, dado un conjunto de características elegidas por la persona usuaria (por ejemplo, un ambiente tranquilo para trabajar), las cafeterías cuyas reseñas mejor las describen.
- **Entregar la solución.** Poner el modelo a disposición mediante una interfaz web sencilla y evaluar su funcionamiento con indicadores y ejemplos reales.

Como se señaló, las plataformas más utilizadas no ofrecen una búsqueda de este tipo. Por esta razón, Geometra plantea un modelo de negocio basado en la recomendación por similitud, con un enfoque parecido al de servicios como Netflix o Spotify, en los que la recomendación busca que la persona encuentre con mayor facilidad lo que le interesa y, con ello, utilice el servicio con mayor frecuencia. La recomendación a partir de la similitud del contenido es una de las técnicas clásicas de los sistemas de recomendación (Ricci et al., 2015). En una etapa posterior, ese mismo conocimiento sobre los establecimientos de una zona podría ofrecerse como insumo para decisiones de inversión o de expansión comercial.

3. Descripción de los datos

Los datos del proyecto provienen de dos tipos de fuentes que cumplen funciones distintas. Por una parte, las fuentes oficiales del INEGI, que son el Marco Geoestadístico y el Directorio Estadístico Nacional de Unidades Económicas (DENUE) (INEGI, s.f.), permiten dimensionar el sector de alimentos y bebidas de Mérida y ubicarlo en el territorio; en este documento se emplean como contexto. Por otra parte, la información de Google, que comprende los datos de

Google Places (Google, s.f.) y las reseñas publicadas en Google Maps, constituye el universo de cafeterías y el texto sobre el que se construye el recomendador. En esta sección se describen primero las fuentes oficiales y el panorama del sector que se obtiene de ellas, y a continuación se presenta el análisis exploratorio de los lugares y de las reseñas de Google.

3.1. Fuentes oficiales: contexto del sector

Alcance de esta subsección. El análisis que se presenta a continuación es únicamente informativo. Sus cifras no se utilizan como entrada del modelo ni para validar el conjunto de cafeterías del recomendador, cuyo universo se obtiene de Google Places, fuente que refleja con mayor cercanía la realidad actual del sector (véase el cierre de esta subsección). Se recurre a fuentes oficiales porque ofrecen un contexto verificable y de cobertura amplia sobre el fenómeno que motiva el proyecto.

3.1.1. Marco Geoestadístico y AGEB

El Marco Geoestadístico es un sistema único y de carácter nacional diseñado por el INEGI, que divide el territorio del país en áreas de referencia geográfica para la información estadística de los censos y las encuestas (INEGI, 2023). Se organiza en tres niveles de desagregación: las áreas geoestadísticas estatales (AGEE), las municipales (AGEM) y las áreas geoestadísticas básicas (AGEB).

Una **AGEB** es la división territorial de un municipio con fines de cobertura y control de la información, y es el nivel más detallado que se utiliza en este proyecto. Se clasifica en dos tipos (INEGI, 2023):

- **AGEB urbana.** Subdivide una localidad urbana en conjuntos de 1 a 50 manzanas. Una localidad es urbana cuando tiene 2,500 habitantes o más, o bien es cabecera municipal.
- **AGEB rural.** Comprende la parte del municipio que no forma parte de las localidades urbanas, es decir, las localidades rurales y las extensiones naturales que las rodean.

En este proyecto se utiliza la versión 2024 del Marco Geoestadístico (INEGI, 2024). Para el municipio de Mérida (clave 31050) esta versión contiene 546 AGEB, de las cuales 541 son urbanas y 5 rurales. Las 541 urbanas abarcan la mancha urbana principal y algunas localidades urbanas del municipio que aparecen separadas de ella en los mapas de esta sección.

El análisis se restringe a las AGEB urbanas de Mérida por las siguientes razones:

- **Cobertura prácticamente completa.** En el corte de 2026, 7,918 de los 7,922 establecimientos del subsector 722 registrados en el municipio (99.95 %) y 956 de los 958 del código 722515 (99.79 %) se ubican dentro de una AGEB urbana, por lo que la restricción prácticamente no excluye establecimientos.
- **Mismo marco territorial que la extracción de Google.** La malla de búsqueda con la que se consultó Google Places se construyó sobre las 541 AGEB urbanas, de modo que ambas fuentes describen la misma zona de la ciudad.

- **Unidad de análisis comparable.** La AGEB es una división oficial, con clave geoestadística única, sobre la que se pueden agregar conteos y elaborar mapas de todo el municipio con el mismo criterio.

3.1.2. Directorio Estadístico Nacional de Unidades Económicas

El DENUE es el directorio del INEGI que reúne la ubicación, la actividad económica y el tamaño de las unidades económicas activas del país (INEGI, s.f.). Cada registro incluye, entre otros datos, el nombre y la dirección del establecimiento, sus coordenadas geográficas, la clase de actividad según el Sistema de Clasificación Industrial de América del Norte (SCIAN) y el estrato de personal ocupado.

En este proyecto interesa el subsector 722, *Servicios de preparación de alimentos y bebidas*, y dentro de él la clase 722515, *Cafeterías, fuentes de sodas, neverías, refresquerías y similares*. Esta clase es la más cercana a una cafetería, pero tiene dos limitaciones: agrupa en un mismo código negocios que el proyecto no considera cafeterías, como las neverías, y no todas las cafeterías de la ciudad se registran en ella, pues algunas se clasifican como restaurantes u otros servicios de preparación de alimentos. Por esta razón el análisis se hace con dos enfoques en paralelo: el subsector 722 completo y el segmento 722515.

El DENUE se actualiza mediante cortes periódicos, pero sus identificadores no se conservan de manera estable entre cortes, lo que impide dar seguimiento a un mismo establecimiento en el tiempo y hace que cortes distantes entre sí no sean comparables. Por esta razón, el análisis de este documento se limita a los tres cortes más recientes disponibles: noviembre de 2024, mayo de 2025 y mayo de 2026. La comparación se hace mediante conteos agregados entre estos tres cortes, y no se sigue a cada establecimiento de manera individual.

3.1.3. Panorama del sector entre 2024 y 2026

Entre 2024 y 2026 los establecimientos del subsector 722 en las AGEB urbanas de Mérida aumentan de 7,517 a 7,918 (5.3 %). El código 722515 pasa de 870 a 956 establecimientos, un aumento de 9.9 %, frente a 4.7 % en el resto del subsector (Tabla 1 y Figura 1). Entre los diez códigos con al menos 100 establecimientos en 2026, el 722515 ocupa el tercer lugar en crecimiento relativo, después de los servicios de preparación de otros alimentos para consumo inmediato (722519, 12.7 %) y de los restaurantes de pizzas, hamburguesas, *hot dogs* y pollos rostizados para llevar (722517, 10.7 %).

Estas variaciones deben leerse con cautela: los tres cortes no están espaciados de manera uniforme (seis meses entre el primero y el segundo, doce entre el segundo y el tercero), y el aumento combina aperturas reales con mejoras en la cobertura del directorio, sin que los datos permitan separarlas.

En cuanto a la expansión geográfica del segmento, 308 AGEB tienen establecimientos del código 722515 en ambos cortes (2024 y 2026), 18 pasan de no tener ninguno a tener al menos uno y 2 dejan de tener; las 213 restantes no registran el segmento en ninguno de los dos cortes (Figura 2).

En conjunto, las fuentes oficiales muestran un crecimiento del segmento 722515 superior al del resto del sector entre 2024 y 2026, sin que sea posible separar las aperturas reales de las mejoras del directorio ni distinguir las cafeterías de otros negocios del mismo código.

Tabla 1. Establecimientos en las AGEB urbanas de Mérida por corte del DENUE. La variación corresponde al periodo de 2024 a 2026. Fuente: elaboración propia con datos del DENUE (INEGI, s.f.) y del Marco Geoestadístico (INEGI, 2024).

Corte	Subsector 722	Resto del 722	Segmento 722515	Peso del 722515 (%)
Noviembre de 2024	7,517	6,647	870	11.6
Mayo de 2025	7,827	6,890	937	12.0
Mayo de 2026	7,918	6,962	956	12.1
Variación (%)	5.3	4.7	9.9	

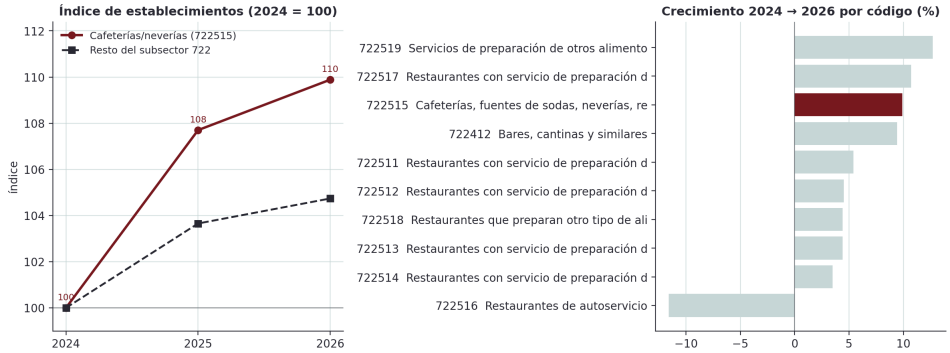


Figura 1. Evolución del segmento 722515 frente al resto del subsector 722 (índice, 2024 = 100) y crecimiento entre 2024 y 2026 de los códigos SCIAN con al menos 100 establecimientos en 2026. Fuente: elaboración propia con datos del DENUE (INEGI, s.f.) y del Marco Geoestadístico (INEGI, 2024).

Como referencia, la información de Google Places, una vez depurada, identifica 1,619 lugares clasificados como cafeterías o negocios afines en la misma zona urbana, cifra superior a los 956 registros del código 722515. Por esta razón el universo de cafeterías del recomendador

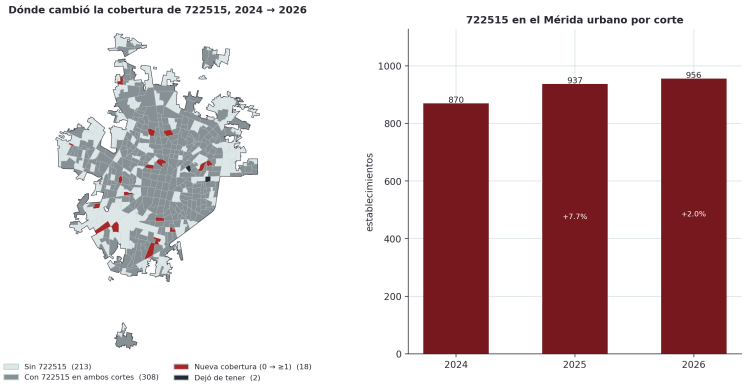


Figura 2. Cambio en la cobertura del segmento 722515 por AGEB urbana entre 2024 y 2026 (izquierda) y número de establecimientos por corte (derecha). Fuente: elaboración propia con datos del DENUE (INEGI, s.f.) y del Marco Geoestadístico (INEGI, 2024).

proviene de Google Places, cuyo panorama actual se presenta en la Sección 3.2; el DENUE se conserva únicamente como referencia de tendencia.

3.2. Google Places: análisis exploratorio de los lugares

Después de la depuración descrita en la Sección 4.3, la base de lugares contiene 1,619 cafeterías y negocios afines en operación dentro de la zona urbana de Mérida, sin identificadores repetidos. Por tipo principal predominan `coffee_shop` (1,239 lugares, 76.5 %) y `cafe` (243, 15.0 %), que en conjunto suman 91.5 %; el resto son restaurantes, panaderías y negocios de postres, entre otros.

Google reporta la calificación y el número de reseñas de 1,230 lugares (76.0 %); los 389 restantes no tienen reseñas registradas. La calificación es alta y se concentra en el extremo superior de la escala: la media es 4.60 y la mediana 4.80, 73.8 % de los lugares tiene 4.5 o más (37.0 % exactamente 5.0) y solo 9.2 % queda por debajo de 4.0 (Figura 3, izquierda). El número de reseñas, en cambio, está muy sesgado: la mediana es de 14 por lugar, 45.0 % de los lugares tiene 10 o menos y 45 superan las mil, con un máximo de 7,006 (Figura 3, derecha). Ambas variables se relacionan de forma inversa: la correlación de Spearman entre el número de reseñas y la calificación es de $-0{,}41$, y la mediana de la calificación pasa de 5.0 en el cuarto de lugares con menos reseñas (3 o menos) a 4.6 en el que tiene más (más de 71). Esto sugiere que una parte de las calificaciones perfectas proviene de lugares con muy pocas reseñas, en los que es más fácil obtener un promedio extremo, por lo que la calificación debe interpretarse junto con el número de reseñas que la respalda.

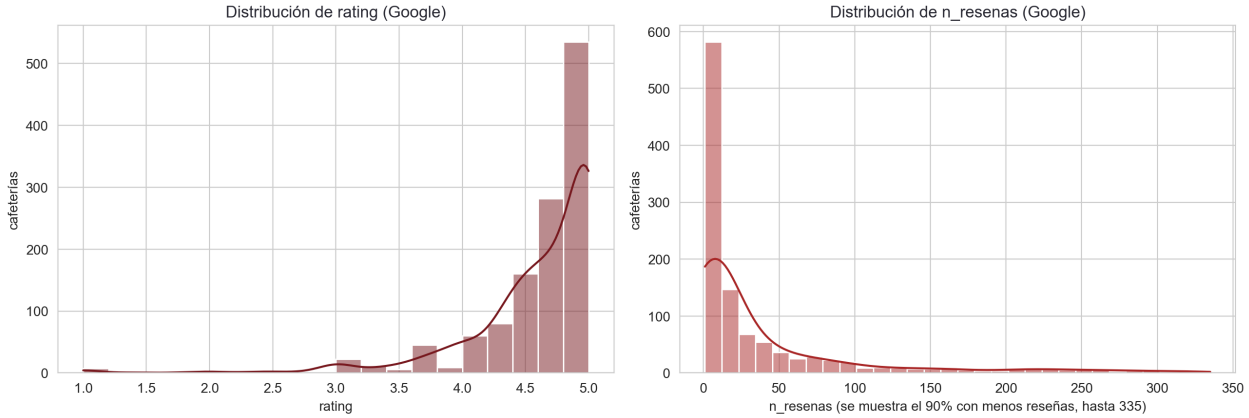


Figura 3. Distribución de la calificación (izquierda) y del número de reseñas (derecha) de los 1,230 lugares con reseñas en Google, con la curva de densidad estimada (KDE). Del número de reseñas se muestra el 90 % de los lugares con menos reseñas (hasta 335). Fuente: elaboración propia con datos de Google Places (Google, s.f.).

La Figura 4 muestra los 1,619 lugares sobre las 541 AGEB urbanas. Los lugares cubren toda la mancha urbana, con mayor densidad en la zona central y hacia el norte, y menor presencia hacia las orillas. En cuanto a la calificación (izquierda), predominan los tonos verdes en toda la ciudad y los lugares con calificaciones bajas son escasos y aislados, sin formar una zona identificable. En cuanto al tipo de negocio (derecha), `coffee_shop` predomina en toda la ciudad.

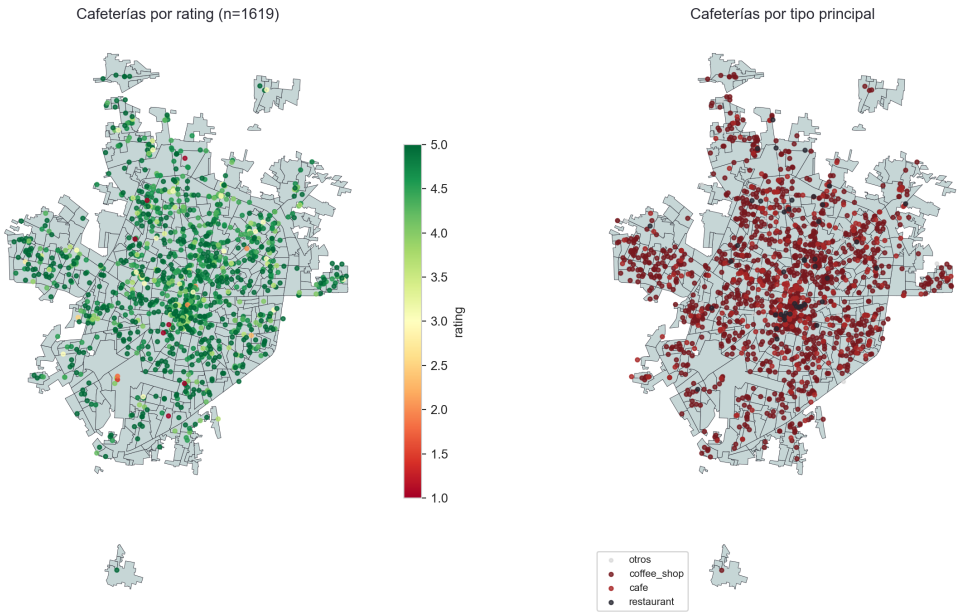


Figura 4. Cafeterías sobre las AGEB urbanas de Mérida, según su calificación en Google (izquierda) y según su tipo principal (derecha; se distinguen los tres tipos más frecuentes). Fuente: elaboración propia con datos de Google Places (Google, s.f.) y del Marco Geoestadístico (INEGI, 2024).

La Figura 5 resume los lugares por AGEB. De las 541 AGEB urbanas, 403 (74.5 %) tienen al menos una cafetería, con un promedio de 4.0 por AGEB ocupada; 92 tienen solo una y 21 tienen 10 o más, con un máximo de 35. La oferta se concentra en unas cuantas AGEB de la zona central: las 10 con más cafeterías reúnen 211 lugares, 13.2 % de los 1,603 ubicados dentro de una AGEB. La calificación promedio por AGEB, que se calcula solo para las 232 con al menos tres cafeterías, es alta y homogénea: la mediana es 4.7 y 94.4 % tiene 4.0 o más. Solo tres quedan por debajo de 3.5 y en dos de ellas los lugares tienen en promedio una y seis reseñas, respectivamente; es decir, hay muy poca evidencia. Por último, el número promedio de reseñas por lugar es alto en pocas AGEB, en parte porque algunos lugares con muchas reseñas elevan el promedio, por lo que este indicador refleja más la popularidad de esos lugares que la densidad de la oferta.

3.3. Reseñas de Google Maps: análisis exploratorio de las reseñas

La base de reseñas contiene 17,422 reseñas de 1,223 lugares, con una mediana de 15 por lugar y un máximo de 25, tope fijado en la extracción (Sección 4.4). De ellas, 15,685 (90.0 %) incluyen texto y 1,737 solo la calificación en estrellas.

La calificación es marcadamente positiva: 77.2 % de las reseñas tiene cinco estrellas y 8.8 % cuatro, mientras que las de una y dos estrellas suman 9.9 % (7.4 % y 2.5 %); la media es 4.46 (Figura 6, centro). El texto es breve, con una mediana de 147 caracteres (media de 212 y un máximo de 4,014). Las reseñas de una a tres estrellas son más largas que las de cinco: sus medianas van de 247 a 276 caracteres, frente a 127, lo que es coherente con que una mala experiencia se explique con más detalle (Figura 6, derecha). Este desbalance condiciona el análisis del texto: hay 13,400 reseñas con texto y calificación de 4 o 5, y solo 1,636 con

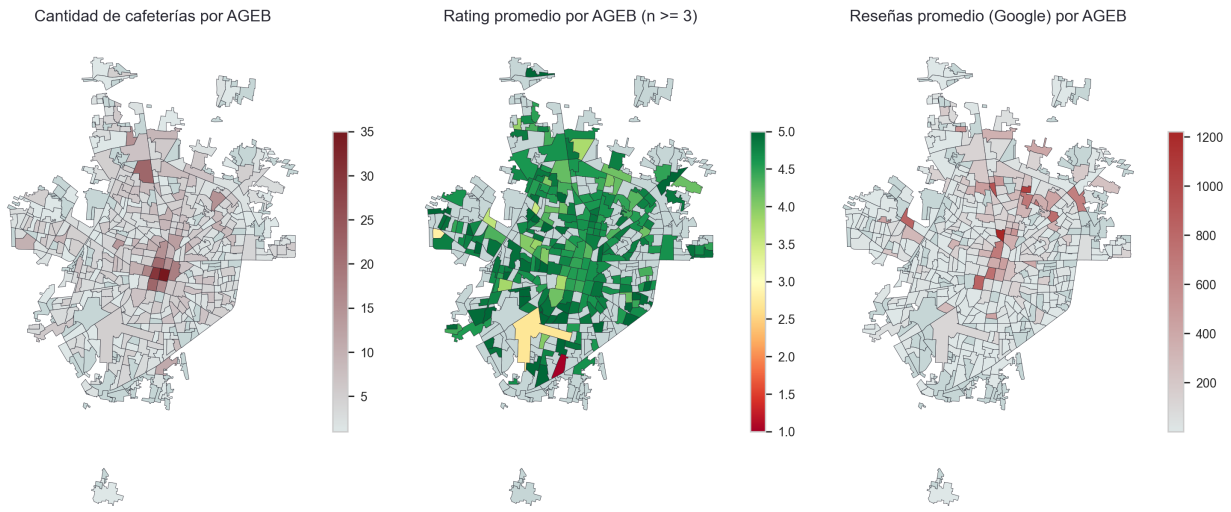


Figura 5. Cantidad de cafeterías (izquierda), calificación promedio (centro) y número promedio de reseñas por cafetería (derecha) por AGEB urbana. La calificación promedio solo se calcula en las AGEB con al menos tres cafeterías; las AGEB sin dato se muestran en gris. Fuente: elaboración propia con datos de Google Places (Google, s.f.) y del Marco Geoestadístico (INEGI, 2024).

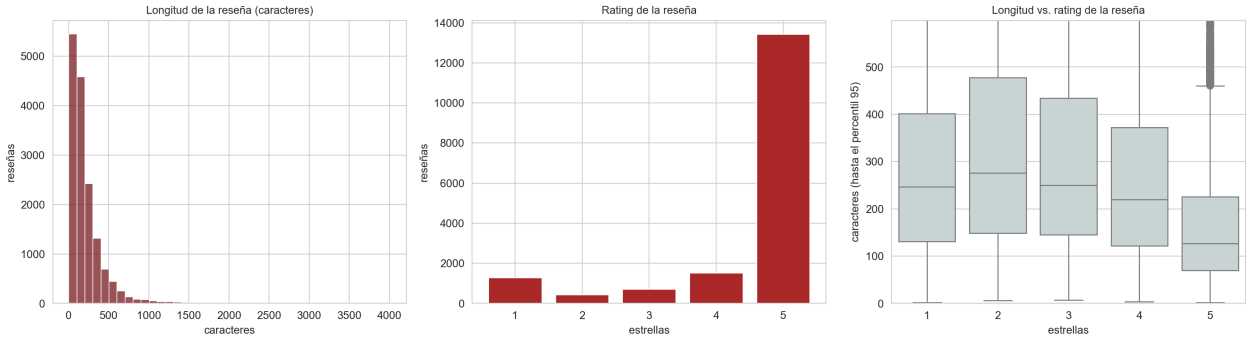


Figura 6. Distribución de la longitud del texto (izquierda), de la calificación (centro) y de la longitud según la calificación (derecha) en las reseñas de Google Maps. En el panel derecho se omite el 5 % de las reseñas más largas. Fuente: elaboración propia con reseñas de Google Maps.

calificación de 1 o 2.

Para identificar de qué se habla en las reseñas se contaron los bigramas (pares de palabras consecutivas) más frecuentes, una vez eliminadas las palabras vacías, por separado en las reseñas positivas (4 o 5 estrellas) y en las negativas (1 o 2 estrellas), como muestra la Figura 7. En las positivas dominan los elogios generales, como *excelente servicio* (704), *excelente lugar* (622), *comida rica* (463) y *comida deliciosa* (435). El bigrama más frecuente, *10 10* (715), corresponde a calificaciones escritas en el texto, por ejemplo *10/10*, y *vale pena* equivale a *vale la pena*, pues las palabras vacías se eliminan antes de formar los pares. En las negativas predominan las críticas al servicio y a la atención, como *pésimo servicio* (109), *mal servicio* (60), *mala experiencia* (51) y *atención cliente* (44), junto con menciones de tiempo (*media hora*, 21). Expresiones como *lugar bonito* (42) y *buen sabor* (27) también figuran entre las más

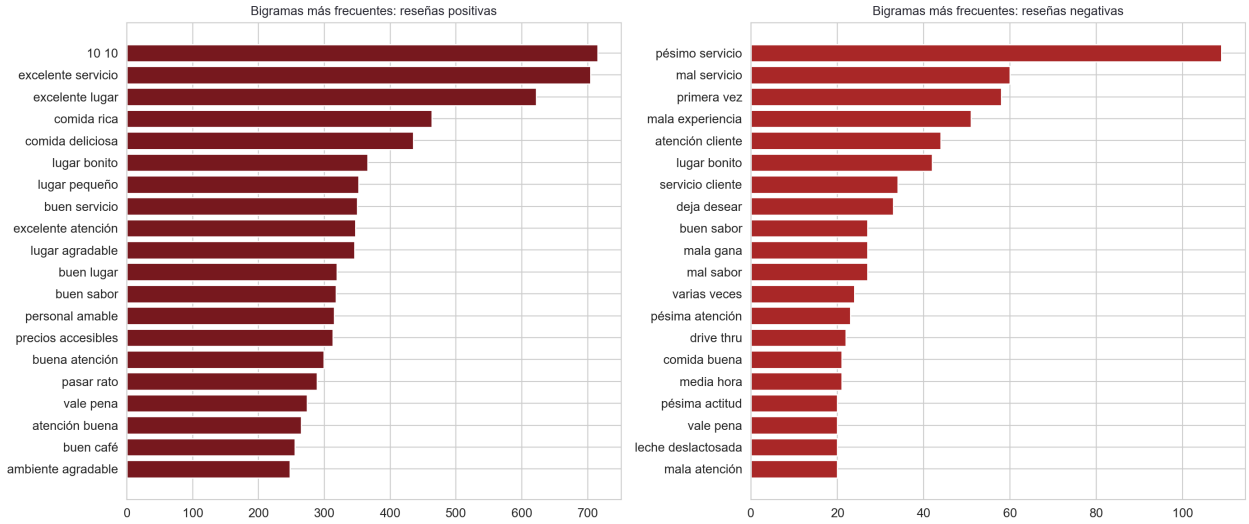


Figura 7. Bigramas más frecuentes en las reseñas positivas (izquierda, 13,400 reseñas) y en las negativas (derecha, 1,636 reseñas), sin palabras vacías. Fuente: elaboración propia con reseñas de Google Maps.

frecuentes en las negativas, lo que sugiere que las críticas se dirigen sobre todo al trato y no al lugar o al producto. En ambos grupos predomina la valoración general y no los atributos concretos del lugar, por lo que estos términos no bastan como etiquetas para filtrar según el uso; por ello, las etiquetas se seleccionaron de forma manual (Sección 5.5).

La Figura 8 presenta las palabras individuales más frecuentes de cada grupo (hasta 150), con tamaño proporcional a su frecuencia. En ambos grupos destacan *lugar*, *café*, *servicio*, *comida* y *atención*, que señalan los temas de los que se habla; lo que cambia es el tono, con *excelente*, *rico*, *delicioso* y *buen* en las positivas frente a *mal*, *mala* y *pésimo* en las negativas.

Para contrastar la calificación con lo que expresa el texto, a las 15,685 reseñas con texto se aplicó el modelo preentrenado `nlptown/bert-base-multilingual-uncased-sentiment` (NLP Town, s.f.). Se trata de un modelo de lenguaje BERT multilingüe, ajustado por sus autores con reseñas de productos en varios idiomas, que recibe un texto y le asigna de 1 a 5 estrellas. Se utilizó sin ajuste adicional, pues no se cuenta con reseñas etiquetadas propias, y su desempeño se verificó contra la calificación que la propia persona asignó a cada reseña: coincide exactamente en 76.4 % de los casos y con una diferencia de una estrella o menos en 95.6 % (Figura 9, derecha). El acuerdo es mayor en los extremos (73 % en las reseñas de una estrella y 84 % en las de cinco) y menor en las intermedias, donde las respuestas se reparten entre estrellas adyacentes; en las de cuatro estrellas, por ejemplo, 45 % coincide y 27 % recibe cinco.

Después, el sentimiento se promedió por lugar y se comparó con la calificación de Google (Figura 9, izquierda). En los 1,111 lugares con al menos una reseña con texto la correlación es de 0.77, y de 0.86 en los 771 con al menos cinco; en los 340 con menos de cinco es de 0.69, pues el promedio depende de muy pocos textos. En general el modelo es más severo que quien escribe: la media del sentimiento por reseña es 4.29, frente a 4.44 de la calificación de esas mismas reseñas. Las diferencias más notables se concentran en pocos lugares: de los 771 con al menos cinco reseñas con texto, 38 tienen un sentimiento más de una estrella por



Figura 8. Palabras más frecuentes en las reseñas positivas (izquierda) y negativas (derecha), sin palabras vacías; el tamaño es proporcional a la frecuencia. Fuente: elaboración propia con reseñas de Google Maps.

debajo de su calificación de Google y ninguno lo tiene más de una por encima. Por ejemplo, dos sucursales de Starbucks tienen calificaciones de 4.5 y 4.4 y sentimientos promedio de 2.5 y 2.9, mientras que Caneroll MID, en sentido contrario, tiene 3.6 y 4.6. Estas brechas indican que el texto contiene información que la calificación por sí sola no captura, aunque una parte puede deberse a errores del modelo, que se entrenó con reseñas de productos y no de cafeterías. Por esta razón el sentimiento se emplea como variable descriptiva y no interviene en el cálculo de similitud entre cafeterías.

4. Metodología

La metodología se organiza en etapas sucesivas, en las que el resultado de cada una alimenta a la siguiente: la preparación de la referencia geográfica, la lectura del DENUE, la obtención de lugares con Google Places, la extracción de sus reseñas y el análisis exploratorio con el que se preparan los datos para el modelado, que se describe en la Sección 5. Todo el procesamiento se realiza en Python, en *notebooks* de Jupyter, con las bibliotecas *pandas* y *GeoPandas* para el manejo de datos tabulares y geoespaciales y, en la modelación, *sentence-transformers* y *scikit-learn*.

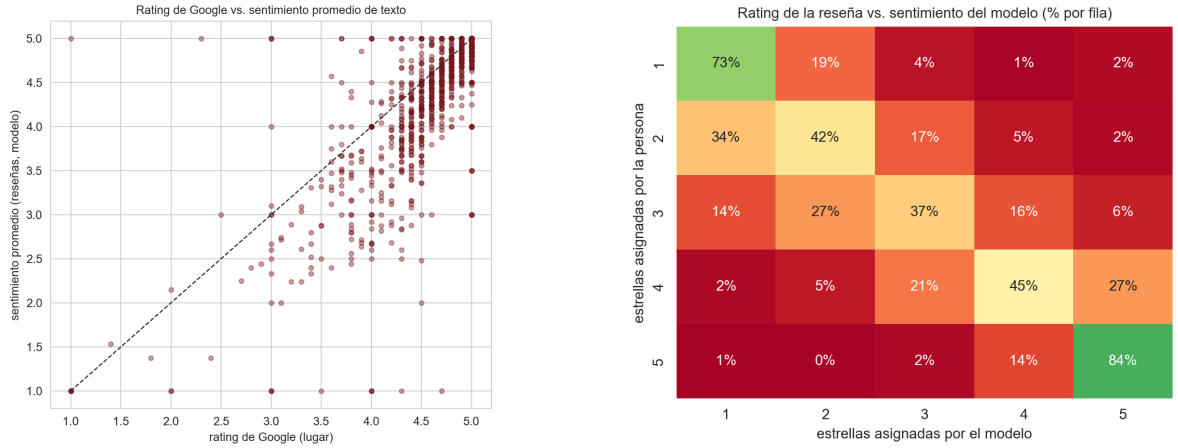


Figura 9. Calificación de Google frente al sentimiento promedio de las reseñas de cada lugar, con la línea de igualdad (izquierda), y calificación de cada reseña frente a las estrellas asignadas por el modelo, en porcentaje por fila (derecha). Fuente: elaboración propia con datos de Google Places (Google, s.f.), reseñas de Google Maps y el modelo de NLP Town (s.f.).

4.1. Preparación de la referencia geográfica

Se descargó el Marco Geoestadístico, versión 2024 (INEGI, 2024), en un archivo comprimido por cada una de las 32 entidades federativas. Cada archivo contiene capas separadas para las AGEB urbanas y rurales, con nombres de campos y claves que difieren entre capas. Para trabajar con una estructura homogénea se estandarizaron, mediante código en Python, las capas de país, entidades federativas, municipios, localidades, AGEB y códigos postales, y cada una se guardó en formato *shapefile*. En el caso de la capa de AGEB, el procedimiento fue el siguiente:

- Se leyeron, para cada entidad, los archivos de AGEB urbanas y de AGEB rurales.
- Se homologaron los nombres de los campos y se construyó la clave geoestadística de cada polígono (`cvegeo`) concatenando las claves de entidad (2 caracteres), municipio (3), localidad (4) y AGEB (4), lo que da 13 caracteres en las AGEB urbanas.
- Se agregó el campo de ámbito (urbano o rural), se reproyectaron todas las capas al sistema de coordenadas geográficas EPSG:4326 y se unieron en una sola capa nacional de 82,123 polígonos.

De esta capa se extrajeron las 541 AGEB urbanas del municipio de Mérida (clave 31050) y se reproyectaron al sistema UTM zona 16N (EPSG:32616), que permite trabajar con distancias y áreas en metros. La unión de estos polígonos, a la que se denomina mancha urbana, es la referencia territorial de los pasos siguientes.

4.2. Lectura del DENUE histórico

Del sitio del INEGI se descargaron los archivos del subsector 722 correspondientes a los tres cortes más recientes del DENUE: noviembre de 2024, mayo de 2025 y mayo de 2026.

Cada archivo tiene cobertura nacional y un tamaño de entre 76 y 155 MB. Se estandarizaron mediante un *notebook* de la siguiente manera:

- **Filtrado.** Se conservaron solo los registros del estado de Yucatán (clave 31).
- **Lectura como texto.** Todas las columnas se leyeron y se guardaron como texto, con el fin de conservar los ceros a la izquierda de las claves geográficas y de los códigos postales.
- **Claves geoestadísticas.** Se agregaron las claves de municipio, localidad, AGEB y manzana (de 5, 9, 13 y 16 caracteres), con la misma convención que la capa de AGEB, junto con el corte y su fecha.
- **Consolidación.** Se apilaron los tres cortes en un solo archivo, con una columna que indica el corte y su fecha.

Para el panorama de la Sección 3 se seleccionaron los registros del municipio de Mérida (clave 050) cuyo código de actividad comienza con 722. Sus coordenadas se convirtieron a EPSG:32616 y cada establecimiento se asignó a la AGEB urbana que lo contiene mediante una unión espacial de punto dentro de polígono. Se optó por asignarlos según su ubicación y no según la clave de AGEB registrada en el directorio, con el fin de no depender de posibles errores de captura de esa clave. Los establecimientos que no caen en ninguna AGEB urbana se descartan (4 de 7,922 en 2026).

Sobre esa base se calcularon los conteos por año, por código de actividad y por AGEB; el índice de crecimiento con 2024 como base; el peso del segmento 722515 dentro del subsector en cada AGEB, solo para las AGEB con al menos cuatro establecimientos del subsector, con el fin de evitar proporciones inestables; la clasificación de las AGEB según si tenían o no establecimientos del segmento en 2024 y en 2026; y la distribución por estrato de personal ocupado.

4.3. Obtención de lugares con Google Places

Dado que el DENUE no permite aislar las cafeterías (véase la Sección 3), el universo de lugares del recomendador se obtuvo directamente de Google Places (API New) (Google, s.f.), mediante la búsqueda por cercanía (*Nearby Search*, punto de acceso `places:searchNearby`). Cada llamada devuelve como máximo 20 lugares, por lo que se diseñó una búsqueda sistemática sobre la mancha urbana. La clave de la API se mantiene en un archivo de variables de entorno externo al código.

- **Malla de búsqueda.** Se generó una malla de celdas de 1,000 por 1,000 m sobre el rectángulo que encierra las 541 AGEB urbanas (de unos 21.7 por 33.4 km), con 748 celdas. Se conservaron las 420 celdas cuyo círculo de búsqueda toca la mancha urbana con un margen adicional de 200 m. El radio del círculo es de unos 707 m, la mitad de la diagonal de la celda, para cubrirla por completo desde su centro. La malla filtrada se exportó a *shapefile* para revisarla visualmente antes de consultar la API.

- **Consulta por celda.** En cada celda se consultaron los tipos `cafe`, `coffee_shop` y `ice_cream_shop`, con resultados en español. Se solicitaron únicamente los campos necesarios: identificador, nombre, dirección, coordenadas, tipo principal y tipos, calificación, número de reseñas, estatus operativo, nivel de precio, resumen editorial y enlaces a Google Maps. Las llamadas se reintentan con espera creciente cuando la API responde con errores temporales, y cada resultado se guarda de inmediato para poder reanudar el proceso sin repetir llamadas.

- **Refinamiento adaptativo.** Cuando una llamada devuelve el máximo de 20 resultados se considera que la celda pudo quedar truncada, por lo que se divide en cuatro cuadrantes que se consultan por separado, hasta dos niveles de subdivisión (de 1,000 a 500 y a 250 m). Este paso es necesario en las zonas más densas.

- **Validación y lote completo.** Antes del lote completo se validó el procedimiento con un piloto de cinco celdas, tres de ellas cercanas al centro de la ciudad, donde se esperaba la mayor densidad. El lote completo produjo 4,288 filas, de las cuales 4,202 corresponden a un lugar encontrado y el resto a celdas sin resultados.

La base obtenida contiene lugares repetidos y de tipos que no corresponden a una cafetería, por lo que se depuró en el siguiente orden:

1. Se descartaron los puntos fuera de la mancha urbana con el margen de 200 m (147 registros).

2. Se eliminaron los duplicados por identificador de lugar, producto del traslape entre celdas vecinas (1,518 registros), y un caso de ficha duplicada en el propio Google Maps (mismo nombre y misma coordenada con identificador distinto), en el que se conservó la ficha con más reseñas. Con ello quedaron 2,536 lugares únicos.

3. Se conservaron solo los lugares con estatus operativo (`OPERATIONAL`), lo que excluyó 225.

4. Se filtraron según la relevancia del tipo principal. Una lista de tipos que no corresponden a una cafetería (por ejemplo, tiendas, hoteles, gimnasios y museos) se excluyó sin excepción. Una lista corta de tipos, validada manualmente, se rescató cuando el lugar figuraba además como cafetería entre sus tipos. Los restaurantes se excluyeron solo cuando sus tipos indicaban una cocina específica, como tacos o pizzas. Asimismo, se excluyeron las neverías (`ice_cream_shop`), pues el alcance del proyecto son las cafeterías y los lugares de postres, y no las neverías que el DENUE agrupa en el mismo código.

5. Se retiraron 33 clubes de nutrición de venta directa que Google clasifica como cafetería, identificados por patrones en el nombre, y un lugar más por revisión manual.

El resultado son 1,619 lugares únicos.

4.4. Extracción de reseñas

La API de Places entrega como máximo cinco reseñas por lugar, por lo que el texto de las reseñas se obtuvo mediante *web scraping* de Google Maps con Selenium y el navegador Chrome, con fines exclusivamente académicos. El proceso fue el siguiente:

- **Universo.** De los 1,619 lugares se excluyeron los 389 que no tienen reseñas registradas en Google Maps (número de reseñas nulo o cero), por lo que se procesaron 1,230 lugares.
- **Acceso.** Para cada lugar se abrió el enlace directo al panel de reseñas que entrega la API. Se utilizó un perfil de Chrome dedicado, con una sesión de Google iniciada, pues sin sesión Google Maps muestra solo unas cuantas reseñas por lugar.
- **Extracción.** Se desplazó el panel de reseñas hasta reunir un máximo de 25 por lugar, las primeras que carga Google Maps, o hasta que ya no se cargaron más. Se expandieron las reseñas con texto truncado y se registraron el nombre de la persona autora, la calificación en estrellas, la fecha relativa y el texto. Los selectores de la página se validaron antes con un piloto de dos lugares, uno con miles de reseñas y otro con pocas.
- **Control de carga.** Con el fin de no saturar el servicio, se aplicaron pausas aleatorias de 3 a 7 segundos entre lugares y una pausa de 30 a 60 segundos cada 50 lugares, y se bloqueó la descarga de imágenes.
- **Continuidad.** Cada lugar se guarda apenas termina y un archivo de avance registra los lugares resueltos, de modo que la corrida se puede reanudar sin repetir trabajo. Los fallos se registran junto con su mensaje de error y el lugar se marca como resuelto, para no detener el proceso.

Se obtuvieron 17,422 reseñas de 1,223 lugares; los 7 restantes fallaron. De ese total, 15,685 reseñas (90 %) incluyen texto y el resto solo la calificación. La mediana es de 15 reseñas por lugar, con un máximo de 25. En la tabla de lugares se agregó una marca que indica si el lugar cuenta con reseñas extraídas (1,223 lugares) o no (396).

4.5. Análisis exploratorio e ingeniería de variables

Con las bases de lugares y de reseñas se realizó un análisis exploratorio y se prepararon los datos para el modelado. Los pasos principales fueron:

- **Asignación de AGEB.** Cada lugar de Google se asignó a la AGEB urbana que lo contiene, con la misma unión espacial empleada para el DENUE. De los 1,619 lugares, 1,603 caen dentro de una AGEB y 16 quedan fuera, muy cerca del borde de la mancha urbana y dentro del margen de tolerancia de la malla de búsqueda.
- **Sentimiento.** A las reseñas con texto se aplicó, sin ajuste fino, el modelo preentrenado `nlptown/bert-base-multilingual-uncased-sentiment`, que asigna de 1 a 5 estrellas a cada reseña; el resultado se promedió por cafetería. El modelo coincide exactamente con la calificación que la propia persona asignó en 76.4 % de las reseñas y con una diferencia de una estrella o menos en 95.6 %, por lo que se considera adecuado como variable descriptiva.

- **Términos frecuentes.** Se calcularon las palabras y los pares de palabras más frecuentes en las reseñas para obtener candidatos a etiquetas con las que filtrar los resultados según el uso del lugar. La selección final se hace de forma manual.

- **Bases para el modelado.** Se generaron una tabla de lugares (1,619 filas, con AGEB y agregados de reseñas) y una de reseñas (17,422 filas, con sentimiento y una marca de reseña sin texto). En la tabla de lugares se agregaron además dos marcas. La primera identifica a los 1,111 lugares con al menos una reseña con texto, que son los que participan como candidatos a ser recomendados. La segunda distingue, entre ellos, a los 340 con menos de cinco reseñas con texto, cuya representación numérica es menos confiable; se conservan como candidatos, pero señalados como de menor confianza.

4.6. Tratamiento de valores extremos y datos faltantes

Las decisiones sobre valores extremos y datos faltantes se tomaron según el uso que tiene cada variable en el recomendador:

- **Sin imputación.** No se imputó ningún valor. Los 389 lugares sin reseñas en Google no tienen calificación y no se les asignó una. Los 508 lugares sin reseñas con texto se conservan en la base, pero no participan como candidatos a ser recomendados, porque no hay texto con el cual calcular su representación. El valor nulo se reserva para lo que no se pudo calcular, y una cuenta de cero reseñas se registra como cero.

- **Calificaciones extremas.** La distribución de la calificación se concentra en el extremo superior (77.2 % de las reseñas tiene cinco estrellas). No se eliminaron ni se transformaron, pues son valores legítimos y descartarlos dejaría fuera la experiencia de la mayoría; su efecto se atiende al interpretar la calificación junto con el número de reseñas (Sección 3.2).

- **Textos muy largos.** La reseña más larga tiene 4,014 caracteres. No se recortó ninguna, pero el modelo de *embeddings* solo procesa los primeros 128 *tokens* de cada texto, lo que afecta a 7.0 % de las reseñas (Sección 5.1).

- **Pocas reseñas.** Las cafeterías con menos de cinco reseñas con texto se conservan y se marcan como de baja confianza, y su puntaje se pondera (Sección 5.4), en lugar de eliminarlas o de rellenar su representación.

- **Limpieza del texto.** A las reseñas con texto solo se les normalizaron los espacios y los saltos de línea. No se pasaron a minúsculas ni se eliminaron palabras vacías, porque los modelos empleados son preentrenados y esperan texto natural.

5. Modelación

El modelo del proyecto recomienda cafeterías con un único mecanismo que se utiliza de dos maneras: dada una cafetería, devuelve las más parecidas (Función 1), y dado un conjunto de características elegidas por la persona usuaria, devuelve las cafeterías cuyas reseñas mejor las

describen (Función 2). En ambos casos se comparan representaciones numéricas del texto de las reseñas mediante la similitud del coseno. No se entrena ningún modelo ni se ajusta uno existente (*fine-tuning*): se emplea un modelo de lenguaje preentrenado (*transfer learning*) y, dado que no se cuenta con etiquetas de relevancia, el enfoque es no supervisado. Tampoco se aplicó un algoritmo de agrupamiento (*clustering*), pues la recomendación se obtiene directamente de los vecinos más cercanos. El procesamiento de esta sección se encuentra en el *notebook* `06_Modelado.ipynb`.

5.1. Representación numérica de las reseñas

Para convertir el texto en números se utilizó el modelo `paraphrase-multilingual-MiniLM-L12-v2` de la biblioteca `sentence-transformers` (Sentence-Transformers, s.f.). Se trata de un modelo de *embeddings* de oraciones (Reimers y Gurevych, 2019), derivado de MiniLM (Wang et al., 2020) y extendido a varios idiomas mediante destilación de conocimiento (Reimers y Gurevych, 2020): recibe un texto y devuelve un vector de 384 números, de modo que textos con significado parecido quedan cerca entre sí. Se seleccionó porque admite español, requisito de un conjunto de reseñas escritas en ese idioma, y porque es lo bastante ligero para ejecutarse en un procesador convencional, sin tarjeta gráfica.

El procedimiento fue el siguiente:

- **Vector por reseña.** Cada una de las 15,685 reseñas con texto de los 1,111 lugares candidatos se convirtió en un vector de 384 dimensiones. Los vectores se calcularon una sola vez y se guardaron como punto de control, de modo que el *notebook* no los recalcula.

- **Vector por cafetería.** El vector de una cafetería es el promedio de los vectores normalizados de sus reseñas, vuelto a normalizar. Se promedió y no se concatenó el texto de las reseñas porque una concatenación superaría con mucho el límite de longitud del modelo y porque el promedio es menos sensible a una reseña atípica.

El modelo procesa como máximo 128 unidades de texto (*tokens*, fragmentos de palabra) por reseña e ignora el resto. La mediana de una reseña es de 38 *tokens* y el percentil 95 de 148; 1,099 reseñas (7.0 %) superan el límite y se representan solo con su inicio. El truncamiento no es uniforme: afecta a 17.8 % de las reseñas de una y dos estrellas y a 19.0 % de las de tres, frente a 5.1 % de las de cuatro y cinco, pues las críticas suelen ser más largas (Sección 3.3). Por esta razón, el vector de una cafetería puede reflejar menos los detalles de sus críticas más extensas.

5.2. Función 1: de una cafetería a las más similares

La similitud entre dos cafeterías se mide con el coseno del ángulo entre sus vectores, que toma valores entre -1 y 1 y es mayor mientras más parecidos son los textos que representan. Dado que los vectores están normalizados, equivale al producto punto. Para una cafetería elegida se calcula el coseno contra todas las demás y se devuelven las tres más cercanas (vecinos más cercanos), sin incluir a la propia cafetería.

Tabla 2. Diagnóstico de la Función 1 con y sin centrado de los vectores y con y sin ponderación por número de reseñas (Sección 5.4), sobre las 1,111 cafeterías y sus tres vecinos más cercanos. Las apariciones cuentan cuántas veces una cafetería figura entre los tres vecinos de otra. Fuente: elaboración propia.

Indicador	Sin centrar	Sin centrar, ponderado	Centrado	Centrado, ponderado
Coseno medio entre pares	0.684	0.684	0.009	0.009
Coseno medio del vecino 1	0.900	0.895	0.665	0.646
Máximo de apariciones de una cafetería	27	39	20	34
Cafeterías que nunca aparecen (%)	31.5	40.7	22.4	38.4
Asimetría de las apariciones	2.23	2.40	1.66	2.34
Vecinos de la misma marca (%)	4.3	4.3	4.8	5.0

Al inspeccionar los vectores sin ajuste se observó un problema de escala: el coseno medio entre cualquier par de cafeterías es de 0.68 y el del vecino más cercano de 0.90, de modo que casi todas parecen 90 % similares y la medida no distingue entre ellas. Mostrado como porcentaje en una tarjeta, ese valor resultaría engañoso. Para corregirlo se restó a cada vector el promedio de todos (centrado) y se volvió a normalizar. Con ello se reduce además el fenómeno de *hubness* (Radovanović et al., 2010), en el que unos pocos puntos aparecen como vecinos cercanos de muchos otros. La Tabla 2 compara las variantes: con el centrado el coseno medio entre pares baja a 0.01 y el del vecino más cercano a 0.67, el máximo de apariciones de una sola cafetería entre los tres vecinos de otras disminuye de 27 a 20 y la proporción de cafeterías que nunca aparecen baja de 31.5 % a 22.4 %. Por esta razón la Función 1 utiliza los vectores centrados.

No existe una respuesta correcta contra la cual medir esta función, por lo que su validación combina indicadores y revisión de ejemplos. Con la versión final (vectores centrados y ponderación), el coseno con el vecino más cercano tiene una mediana de 0.65 (mínimo 0.30 y máximo 0.91) y, en 5.0 % de los casos, el vecino pertenece a la misma marca que la cafetería, más de 20 veces el 0.2 % que se esperaría al azar (la marca se aproxima con la primera palabra no genérica del nombre). Que las sucursales de una cadena se recomienden entre sí no es el objetivo del modelo, pero es una señal de que los vectores capturan rasgos reales de la experiencia que describen las reseñas. La Figura 10 muestra la distribución del coseno con el vecino más cercano y de las apariciones, y la Tabla 3 presenta los vecinos de cuatro cafeterías.

Los vecinos son coherentes con lo que se esperaría. Las sucursales de una misma cadena se recomiendan entre sí (Starbucks Paseo Montejo), y los tres vecinos de Marmalade Centro comparten con ella el atributo de desayunos, y uno de ellos es otra sucursal de la misma marca. Dunkin' Buenavista tiene por vecinos a otra sucursal de su cadena y a dos de Starbucks, lo que indica que la similitud no se limita al nombre. Por último, una referencia con pocas reseñas, como Caneroll MID (7), obtiene parecidos más bajos, de alrededor de 0.50, en línea con que su vector se promedia sobre pocos textos.

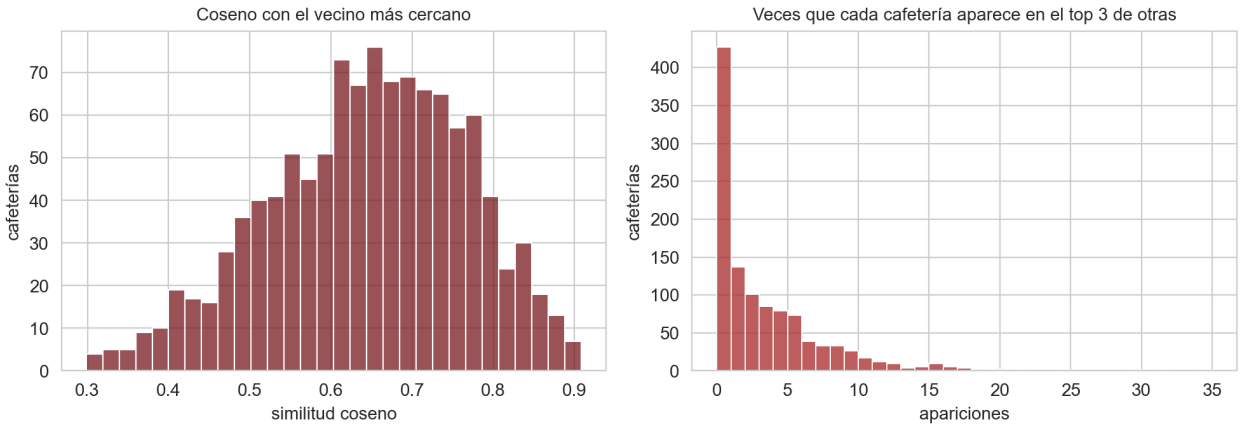


Figura 10. Coseno con el vecino más cercano (izquierda) y número de veces que cada cafetería aparece entre los tres vecinos de otras (derecha), con la Función 1 tal como se implementa (vectores centrados y ponderación). Fuente: elaboración propia.

Tabla 3. Las tres cafeterías más similares a cuatro cafeterías de referencia con la Función 1. Entre paréntesis, el número de reseñas con texto de la referencia. Fuente: elaboración propia.

Cafetería de referencia	Cafeterías similares	Coseno
Starbucks Paseo Montejo (25)	Starbucks Harbor Mérida	0.73
	Starbucks Urban Center Mérida DT	0.69
	Starbucks	0.68
Marmalade Centro (25)	Marmalade Luxury	0.77
	Alma piedra - Temozón	0.76
	La Libertad García Lavín	0.74
Dunkin' Buenavista (25)	Starbucks	0.87
	Dunkin'	0.86
	Starbucks Plaza Las Américas	0.85
Caneroll MID (7)	Frappémania mid	0.50
	Café Boxha at El Parián de la Mejorada	0.49
	CAFETHó Express	0.48

Para observar la estructura del espacio de vectores, las 1,111 cafeterías se proyectaron a dos dimensiones con un análisis de componentes principales a 50 componentes seguido de t-SNE (van der Maaten y Hinton, 2008) (Figura 11). Esta técnica deforma las distancias y el tamaño de los grupos, por lo que la proyección solo se emplea para ver agrupaciones y no para medir; su fidelidad local, medida con la confiabilidad (*trustworthiness*) de los diez vecinos más cercanos, es de 0.95, donde 1 indica que los vecinos del mapa son vecinos reales. Las sucursales de una misma cadena quedan juntas: entre los cinco puntos más cercanos de cada sucursal de Starbucks, 68 % son también de Starbucks (2.3 % al azar), y las proporciones son de 42 % para The Italian Coffee (1.0 %) y de 29 % para Dunkin' (0.8 %). Además, la zona donde se concentran esas cadenas coincide con la de menor sentimiento promedio: las 46 sucursales de las tres cadenas tienen un sentimiento medio de 3.25 estrellas, frente a 4.41

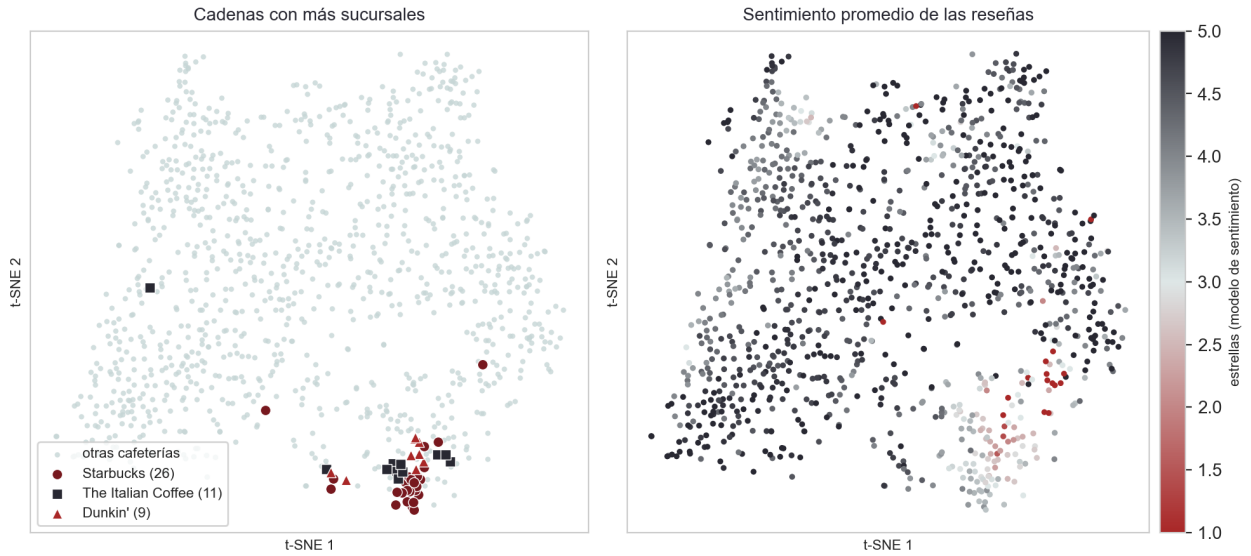


Figura 11. Proyección en dos dimensiones (componentes principales y t-SNE) de los vectores de las 1,111 cafeterías. A la izquierda se resaltan las cadenas con más sucursales; a la derecha, el sentimiento promedio de las reseñas de cada cafetería. Fuente: elaboración propia con reseñas de Google Maps y el modelo de NLP Town (s.f.).

del resto, y reúnen 16 de las 75 cafeterías con sentimiento menor de tres. Las cadenas se identificaron por el nombre del lugar.

5.3. Función 2: de las características a las cafeterías

En la Función 2 la persona elige una o más características de un panel (Sección 5.5). Las elegidas se unen en un solo texto, que se convierte en vector al momento con el mismo modelo y se compara contra los vectores de las cafeterías; se devuelven las diez con mayor puntaje. Una consulta de pocas palabras, como "buen wifi", se compara contra el promedio de muchas reseñas, por lo que se evaluaron dos ajustes que no requieren entrenar nada:

- **Centrar o no los vectores** de las cafeterías, como en la Función 1.
- **Plantilla de consulta.** Convertir las palabras en una oración completa ("Es un lugar con buen wifi"), pues el modelo se entrenó con oraciones y las reseñas son oraciones.

No se cuenta con etiquetas que indiquen qué cafeterías son relevantes para una consulta, por lo que se recurrió a un respaldo léxico: una cafetería se considera relevante para una consulta si al menos dos de sus reseñas mencionan el tema. La mención se detecta con una expresión regular, es decir, un patrón de búsqueda en el texto; por ejemplo, para el ambiente tranquilo se busca la raíz "tranquil", que abarca palabras como *tranquilo*, *tranquila* y *tranquilidad*. Se reportan tres medidas. La primera es la precisión en los primeros k resultados (P@k), es decir, la proporción de los k resultados que son relevantes (Manning et al., 2008), con k igual a 5 y a 10. La segunda es la tasa base, que es la proporción de cafeterías relevantes para la consulta entre las 1,111 candidatas; equivale a la precisión que se obtendría si las cafeterías

Tabla 4. Precisión de la Función 2 según la plantilla de la consulta y el centrado de los vectores, promedio de 16 consultas. La última columna cuenta las consultas sin ningún acierto en los diez primeros resultados. Fuente: elaboración propia.

Plantilla	Vectores	P@5	P@10	*Lift*	Sin aciertos
`{texto}`	sin centrar	0.38	0.38	2.72	5
`{texto}`	centrados	0.35	0.31	2.10	6
`Es un lugar con {texto}`	sin centrar	0.62	0.61	5.63	1
`Es un lugar con {texto}`	centrados	0.54	0.52	4.66	1
`Un lugar con {texto}`	sin centrar	0.60	0.53	4.63	2
`Un lugar con {texto}`	centrados	0.50	0.48	4.12	2
`Cafetería con {texto}`	sin centrar	0.44	0.42	4.33	0
`Cafetería con {texto}`	centrados	0.32	0.41	3.95	1
`Lugar: {texto}`	sin centrar	0.51	0.49	4.04	3
`Lugar: {texto}`	centrados	0.44	0.44	3.69	3
`Este café tiene {texto}`	sin centrar	0.11	0.13	0.68	7
`Este café tiene {texto}`	centrados	0.14	0.13	0.68	7

se ordenaran al azar. La tercera es el *lift*, que se obtiene al dividir P@10 entre la tasa base e indica cuántas veces supera el recomendador al azar: un *lift* de 1 significa que no hay mejora, y uno de 3 significa que se encuentran tres veces más cafeterías relevantes de las que se encontrarían al azar. Por ejemplo, para el ambiente tranquilo 238 de las 1,111 cafeterías son relevantes (tasa base de 0.21), y de las diez primeras recomendadas 7 lo son (P@10 de 0.70), por lo que el *lift* es de 3.27. Se usaron 16 consultas: 12 características individuales y 4 combinaciones de varias, como las armaría la interfaz. La tasa base media de estas consultas es de 0.14.

La Tabla 4 permite tomar cuatro decisiones. Primero, sin plantilla las palabras sueltas rinden poco: P@10 de 0.38 y cinco consultas sin ningún acierto. Segundo, con la plantilla "Es un lugar con {texto}" la precisión sube a 0.61 (*lift* de 5.63) con los vectores sin centrar. Tercero, centrar no ayuda a la Función 2: baja la precisión en cinco de las seis plantillas y la deja igual en la sexta, aunque sí ayuda a la Función 1, por lo que el modelo conserva los dos conjuntos de vectores. Cuarto, el resultado es sensible a la redacción: "Este café tiene {texto}" queda por debajo del azar (*lift* de 0.68), posiblemente porque la palabra "café" aparece en casi todas las reseñas y hace que la consulta se parezca a casi todas las cafeterías. Por esta razón la Función 2 usa los vectores sin centrar y la plantilla "Es un lugar con {texto}". Cabe señalar que la plantilla se eligió con las mismas consultas con que se mide, por lo que la mejora reportada es probablemente algo mayor que la que se obtendría con consultas nuevas.

5.4. Ponderación por número de reseñas

El vector de una cafetería con pocas reseñas se promedia sobre pocos textos, por lo que es poco estable: una cafetería con una sola reseña queda representada por esa reseña y puede obtener un coseno muy alto con una consulta por simple coincidencia. Para que estos casos no ocupen los primeros lugares se definió una confianza igual al número de reseñas con texto dividido entre cinco, con tope de uno, y el puntaje que ordena los resultados es el coseno

Tabla 5. Cafeterías que salen y que entran al top 10 de la consulta "ambiente tranquilo para trabajar" al aplicar la ponderación por número de reseñas. Fuente: elaboración propia.

Cafetería	Reseñas con texto	Coseno	Confianza
Salen al ponderar			
Temazate Café	1	0.78	0.2
COFFE Y BITES	3	0.61	0.6
Montino Cafetería	1	0.58	0.2
Bimbo	2	0.58	0.4
Entran al ponderar			
Sempere Libros y Café	25	0.56	1.0
Starbucks City Center Mérida	25	0.55	1.0
Savarino Galeria Cafe	25	0.55	1.0
Kofi and Tonics	25	0.55	1.0

multiplicado por esa confianza:

$$\text{puntaje} = \text{coseno} \times \text{mín}\left(1,\ \frac{n}{5}\right),$$

donde n es el número de reseñas con texto de la cafetería. Con cinco reseñas o más la confianza vale uno y el puntaje coincide con el coseno. El umbral de cinco es el mismo que define la marca de baja confianza (Sección 4.5).

El efecto se observa en ambas funciones. En la Función 2, la precisión media en los diez primeros resultados de las 16 consultas pasa de 0.44 sin ponderar a 0.61 con la ponderación; sin ella, 57 de las 160 posiciones de esos rankings (35.6 %) corresponden a cafeterías de baja confianza, mientras que con ella no hay ninguna. En la Función 1, las cafeterías de baja confianza son 30.6 % del total, pero solo 0.7 % de los vecinos que se devuelven. La Tabla 5 muestra un caso: en la consulta "ambiente tranquilo para trabajar", la cafetería con el coseno más alto era una con una sola reseña (0.78); con la ponderación su puntaje baja a 0.16 y, junto con otras tres de muy pocas reseñas, sale del ranking, en el que entran cafeterías con 25 reseñas.

La ponderación tiene un costo: las 340 cafeterías de baja confianza casi no se recomiendan y la proporción de cafeterías que nunca aparecen entre los tres vecinos de otra sube de 22.4 % a 38.4 % (Tabla 2). Se aceptó porque un vecino respaldado por pocas reseñas resulta menos útil que uno con más, en línea con la decisión del proyecto de mostrar esas cafeterías sin priorizarlas. Siguen disponibles como cafetería de referencia y en la interfaz se identifican con la etiqueta "Pocas reseñas". El umbral y la forma de la ponderación pueden ajustarse.

5.5. Vocabulario de características y atributos de las tarjetas

La Función 2 necesita un vocabulario de características que la persona pueda elegir, y las tarjetas de resultados muestran hasta tres atributos por cafetería. Ambos salen de una misma lista de 20 características, que se seleccionó de forma manual a partir de los términos más frecuentes de las reseñas (Sección 3.3). Dado que las expresiones más frecuentes son

Tabla 6. Vocabulario de características: evidencia en las reseñas y precisión de la Función 2. Se indican el número de reseñas que mencionan la característica, el número de cafeterías con dos o más de esas reseñas, la tasa base (proporción de esas cafeterías entre las 1,111), la precisión en los diez primeros resultados (P@10) y el *lift*. Fuente: elaboración propia con reseñas de Google Maps.

Característica	Reseñas	Cafeterías	Tasa base	P@10	*Lift*
servicio amable	3,000	574	0.52	1.00	1.94
ambiente tranquilo	866	238	0.21	0.70	3.27
postres ricos	1,123	222	0.20	1.00	5.00
desayunos	1,079	215	0.19	1.00	5.17
panadería	912	195	0.18	1.00	5.70
lugar acogedor	728	186	0.17	0.30	1.79
servicio rápido	717	177	0.16	0.80	5.02
decoración bonita	586	142	0.13	0.80	6.26
para trabajar	485	109	0.10	0.70	7.13
aire acondicionado	456	104	0.09	0.70	7.48
para reunirse con amigos	469	102	0.09	0.60	6.54
buena música	413	100	0.09	0.70	7.78
terraza	288	64	0.06	0.20	3.47
precios accesibles	363	62	0.06	0.50	8.96
estacionamiento	204	48	0.04	0.30	6.94
espacio amplio	230	43	0.04	0.10	2.58
juegos de mesa	193	40	0.04	0.90	25.00
helados	256	32	0.03	0.90	31.25
pet friendly	142	28	0.03	0.20	7.94
buen wifi	147	22	0.02	0.00	0.00

sobre todo elogios generales, como *excelente servicio*, se conservaron las que describen un rasgo concreto del lugar (por ejemplo, *buen wifi* o *para trabajar*) y se descartaron los elogios genéricos. Cada característica lleva una expresión regular que se usa únicamente para verificar su evidencia, es decir, cuántas reseñas la mencionan; el modelo no la emplea para recomendar. Una característica solo se ofrece si al menos 15 cafeterías tienen dos o más reseñas que la mencionan; las 20 cumplen el criterio, y la más escasa, *buen wifi*, cuenta con 22. Cinco de ellas (*helados*, *panadería*, *decoración bonita*, *servicio rápido* y *para reunirse con amigos*) se incorporaron después de una primera lista de 15, una vez que se comprobó que tenían evidencia suficiente y una precisión de 0.6 a 1.0 en los diez primeros resultados (Tabla 6).

Un atributo de tarjeta se muestra como un hecho sobre la cafetería, por lo que debe tener respaldo. Un primer intento, que elegía los atributos solo por la afinidad de su *embedding* con cada característica, tuvo respaldo en las reseñas 37 % de las veces (24 % al azar), un nivel insuficiente. Por esta razón, una característica solo puede ser atributo de una cafetería si al menos dos de sus reseñas la mencionan y, entre las que cumplen, se eligen las tres de mayor afinidad relativa, medida con el puntaje estandarizado (z) de la similitud frente al resto de las cafeterías, con un mínimo de 0.5. Con esta regla, 574 de las 1,111 cafeterías tienen al menos un atributo y se asignaron 1,258 en total; el más frecuente es *servicio amable* (180

cafeterías) y el menos frecuente, *buen wifi* (5).

5.6. Sentimiento como modelo secundario

El sentimiento de las reseñas (Sección 3.3) se calculó con un modelo preentrenado, `nlptown/bert-base-multilingual-uncased-sentiment` (NLP Town, s.f.), basado en BERT (Devlin et al., 2019), que funciona como modelo secundario del proyecto: se consume tal cual, sin ajuste, para producir una variable adicional. Esa variable no interviene en la similitud entre cafeterías; se utiliza de forma descriptiva. El sentimiento promedio de las reseñas de cada cafetería determina la insignia de su tarjeta, con tres categorías: positivo si es de 4.0 estrellas o más, neutro si es de 3.0 o más y menor de 4.0, y negativo si es menor de 3.0. De las 1,111 cafeterías, 879 (79.1 %) son positivas, 157 (14.1 %) neutras y 75 (6.8 %) negativas.

5.7. Evaluación y límites

Resultados. En las 16 consultas de la Función 2, la precisión media en los diez primeros resultados es de 0.61, frente a una tasa base media de 0.14 (un *lift* medio de 5.6). Quince de las 16 consultas tienen al menos un acierto, y ninguna combinación de varias características rinde peor que las características que la componen: "ambiente tranquilo para trabajar" y "postres ricos desayunos" alcanzan una precisión de 1.00, es decir, las diez cafeterías recomendadas son relevantes. La Figura 12 presenta el resultado de cada consulta, con y sin ponderación, y el Anexo B su detalle. Si se evalúan las 20 características del vocabulario final, 14 alcanzan una precisión de al menos 0.5 (Tabla 6).

Lo que no funciona bien. La búsqueda es débil en las características poco frecuentes: "buen wifi" obtiene 0.00; "espacio amplio", 0.10; "terraza" y "pet friendly", 0.20; y "lugar acogedor" y "estacionamiento", 0.30. En cinco de ellas (wifi, espacio amplio, terraza, *pet friendly* y estacionamiento) pocas cafeterías mencionan el tema, entre 22 y 64 con dos o más reseñas, y el promedio de las reseñas de una cafetería diluye una mención aislada entre todas las demás; en "lugar acogedor", que es frecuente, es posible que la idea se exprese con palabras muy distintas. En una prueba exploratoria preliminar, que no forma parte de este documento, agregar por reseña (promediar las reseñas más parecidas a la consulta, en lugar de todas) mejoró estos casos, pero redujo la precisión general. Por eso no se incorporó; además, implicaría cambiar el diseño del modelo, que promedia los *embeddings* de todas las reseñas de cada cafetería.

Las demás limitaciones son las siguientes:

- **Métrica léxica.** La precisión se mide con menciones de palabras y no distingue significados: una reseña que dice "no es tranquilo" cuenta como mención de tranquilidad. Es una aproximación repetible, no una medida de la satisfacción de la persona usuaria.

- **Selección dentro de la muestra.** La plantilla de la consulta se eligió con las mismas consultas con que se mide, por lo que la precisión reportada es algo optimista, y el resultado es sensible a la redacción (Sección 5.3).

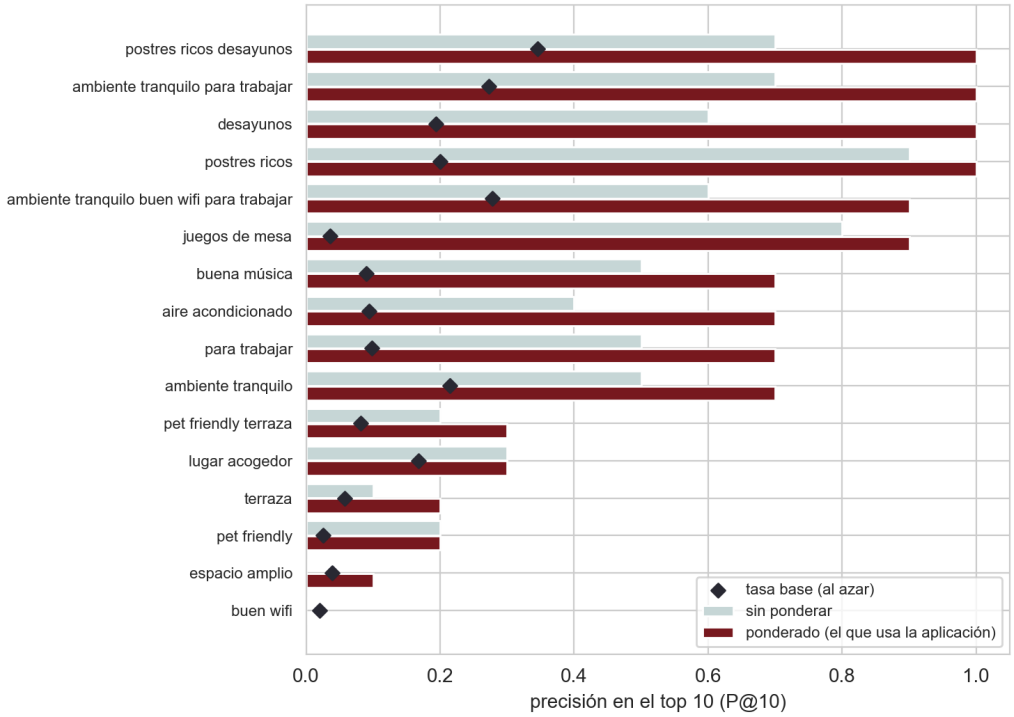


Figura 12. Precisión en los diez primeros resultados (P@10) de cada una de las 16 consultas de la Función 2, con y sin ponderación por número de reseñas, frente a la tasa base de cada consulta. Fuente: elaboración propia.

- **Cobertura.** Solo 1,111 de las 1,619 cafeterías tienen reseñas con texto y pueden recomendarse; las 508 restantes quedan fuera. De las candidatas, 340 tienen menos de cinco reseñas con texto y casi no aparecen en los resultados (Sección 5.4).
- **Muestra de reseñas.** Se extrajeron como máximo 25 reseñas por lugar, las primeras que carga Google Maps, por lo que el vector de una cafetería representa una muestra de sus reseñas y no todas. Además, el modelo trunca las de más de 128 unidades de texto, sobre todo las críticas (Sección 5.1).
- **Cafeterías poco recomendadas.** Con la versión final de la Función 1, 38.4 % de las cafeterías nunca aparece entre los tres vecinos de otra. Siguen disponibles como referencia, pero es una limitación del modelo para descubrirlas.
- **Fuente única.** Todo el texto proviene de Google Maps, donde las calificaciones son muy altas (Sección 3.2), y las reseñas reflejan solo a quienes deciden opinar.

6. Resolución del problema

La pregunta que motivó el proyecto (Sección 2) es cómo recomendar una cafetería a partir de otra que la persona ya conoce, o a partir de las características que busca, con base en lo que expresan sus clientes. El modelo de la Sección 5 la responde con los siguientes pasos:

1. **Representación.** El texto de las reseñas de cada cafetería se resume en un vector de 384 números, que se calcula una sola vez y se guarda.
2. **Consulta.** La persona elige una cafetería (Función 1), cuyo vector ya existe, o una o más características (Función 2), cuyo texto se convierte en vector al momento.
3. **Comparación.** Se calcula el coseno contra todas las cafeterías y se pondera por el número de reseñas con texto.
4. **Resultado.** Se devuelven las tres (Función 1) o las diez (Función 2) de mayor puntaje, cada una con su calificación, su sentimiento, hasta tres atributos y su ubicación en el mapa.

Un caso de la Función 1. Con Marmalade Centro como referencia (Tabla 3), la persona obtiene Marmalade Luxury, Alma piedra - Temozón y La Libertad García Lavín, con puntajes de 77 %, 76 % y 74 %. Según sus propias reseñas, las tres comparten con la referencia el atributo de desayunos y dos de ellas el de servicio amable. El porcentaje que muestra la tarjeta es el puntaje de similitud multiplicado por 100; no es una probabilidad ni una medida de calidad.

Dos casos de la Función 2. La Tabla 7 presenta los primeros cinco resultados de una consulta que funciona bien y de una que falla. En "ambiente tranquilo para trabajar", las cinco cafeterías tienen entre dos y cinco reseñas que mencionan alguno de los dos temas, de modo que todas cumplen el criterio de relevancia de la Sección 5.3. En "buen wifi", en cambio, ninguna lo cumple: cuatro de las cinco no tienen ninguna reseña que mencione el tema y una tiene una sola. El modelo devuelve cafeterías con un parecido general a la consulta, pero sin evidencia del atributo, que es el límite descrito en la Sección 5.7. Por esta razón, el resultado debe leerse como las cafeterías que más se parecen a lo elegido y no como un filtro que garantice la característica.

La Tabla 8 relaciona los objetivos del proyecto con lo que se obtuvo de cada uno.

7. Interfaz de uso

El modelo se puso a disposición mediante una aplicación web llamada Locus, un producto de Geometra. Esta sección describe su arquitectura y su diseño, explica su uso paso a paso, reporta las pruebas realizadas y detalla cómo se publicó en internet.

7.1. Arquitectura

La aplicación tiene dos partes que se comunican por internet: un servicio de datos y una interfaz de usuario. El servicio está construido con FastAPI, en Python, y carga el modelo de la Sección 5 al iniciar; como los vectores se calculan de antemano, en cada consulta solo compara vectores. El único cálculo pesado es la conversión a vector del texto de la Función 2. El servicio ofrece cuatro consultas:

- `/cafes`. Las 1,111 cafeterías recomendables, con su ubicación, calificación, sentimiento y atributos, para el buscador y el mapa.

Tabla 7. Primeros cinco resultados de la Función 2 para dos consultas. La última columna es el número de reseñas de la cafetería que mencionan el tema (en la primera consulta, cualquiera de los dos temas). Fuente: elaboración propia.

Cafetería	Reseñas con texto	Coseno	Reseñas que mencionan el tema
Consulta: "ambiente tranquilo para trabajar"			
The coffee belt	10	0.66	4
Starbucks Paseo Montejo	25	0.64	5
Starbucks Harbor Mérida	25	0.58	2
Starbucks Urban Center Mérida DT	25	0.58	5
Starbucks	25	0.57	5
Consulta: "buen wifi"			
Snoopy Frapp Frappes del parque	7	0.55	0
Sala De Fiestas "El Cielito"	7	0.55	0
Modulo 3 Paseo Verde	17	0.53	0
Starbucks	25	0.53	1
Joa's Coffee Mérida Norte	7	0.53	0

Tabla 8. Objetivos del proyecto y resultados. Fuente: elaboración propia.

Objetivo	Resultado	Sección
Construir el conjunto de reseñas	1,619 lugares de Google Places depurados y 17,422 reseñas de 1,223 lugares, de las que 15,685 tienen texto	4.3, 4.4
Representar las reseñas de forma numérica	Un vector de 384 dimensiones por reseña y por cafetería (1,111 cafeterías candidatas)	5.1
Medir la similitud	Coseno con vectores centrados; el vecino más cercano de una cafetería tiene un coseno mediano de 0.65	5.2
Permitir la búsqueda por características	Precisión media de 0.61 en los diez primeros resultados frente a 0.14 al azar, con debilidad en las características poco frecuentes	5.3, 5.7
Entregar la solución	Aplicación web con las dos funciones y un mapa, publicada en https://geometra-locus.vercel.app; tiempos de respuesta medianos de 6 ms y 56 ms en el servicio local de desarrollo	7

- `/cafe/{place_id}`. El detalle de una cafetería.
- `/tags`. El vocabulario de características de la Sección 5.5.
- `/recommend`. La recomendación, en dos modos: `place`, que recibe la cafetería de referencia y devuelve las tres más similares (Función 1), y `text`, que recibe las características elegidas y devuelve las diez que mejor las describen (Función 2).

La interfaz de usuario está construida con Vue 3 y TypeScript, con estilos de Tailwind CSS,

y dibuja las cafeterías en un mapa de Leaflet con datos de OpenStreetMap. Las cafeterías, sus vectores y el vocabulario provienen del archivo que genera el *notebook* de modelado, por lo que actualizar el modelo no requiere modificar el código de la aplicación.

7.2. Diseño

La aplicación tiene tres páginas: una portada donde la persona elige si es usuaria de cafeterías o dueña de una, la página de recomendación y una página para negocios que se encuentra en desarrollo y solo invita a contactar al equipo. La barra superior, presente en todas, incluye el acceso a las páginas y un botón de contacto.

La página de recomendación es el núcleo de la aplicación. Su distribución se muestra en la Figura 13: un selector de la función a usar, un mapa que ocupa 60 % del ancho y un panel de resultados en el 40 % restante. Al cambiar de función solo cambia el panel; el mapa no se recarga. En la primera función el panel incluye un buscador de cafeterías, y en la segunda un cuadro con las 20 características. Cada resultado se presenta en una tarjeta con el nombre y la dirección corta, la calificación en estrellas, la insignia de sentimiento (positivo, neutro o negativo), hasta tres atributos y, en su caso, la etiqueta "Pocas reseñas". En el mapa, la cafetería de referencia se marca en rojo y las recomendadas en gris.

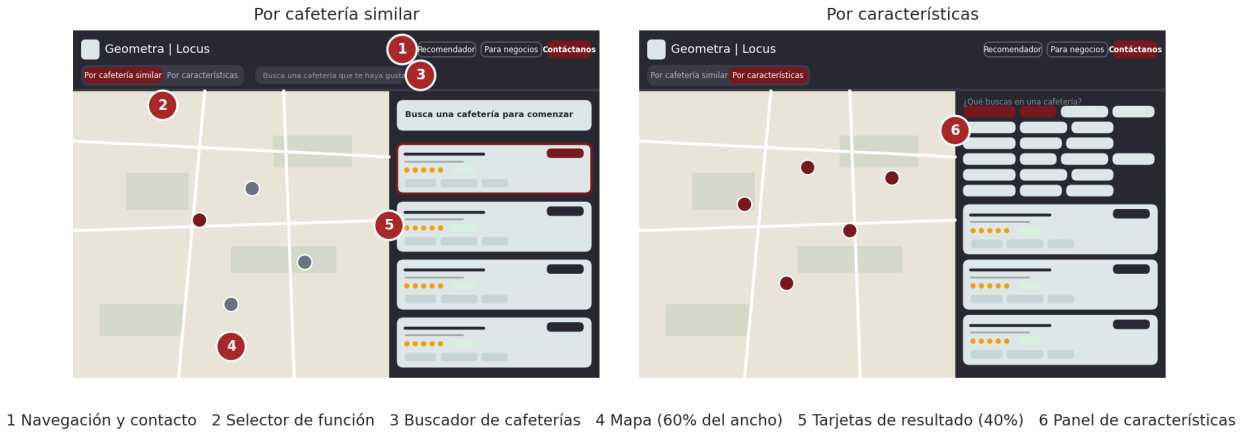


Figura 13. Esquema de la página de recomendación en sus dos funciones. Los números indican los componentes: (1) navegación y contacto, (2) selector de función, (3) buscador, (4) mapa, (5) tarjetas de resultado y (6) panel de características. Fuente: elaboración propia.

Para que la página no se vea vacía antes de elegir, la primera función propone al inicio seis cafeterías al azar, escogidas entre las que tienen cinco reseñas con texto o más, que se muestran como tarjetas y como puntos en el mapa; basta pulsar una para usarla como referencia. El listado del buscador se ordena alfabéticamente y coloca al final los nombres que empiezan con un símbolo.

7.3. Guía de uso

Función 1: buscar cafeterías similares a una que gustó.

1. En la portada, elegir *Usuario de Cafeterías*.

2. En *Por cafetería similar*, escribir el nombre de una cafetería en el buscador y elegirla de la lista, o bien pulsar una de las seis cafeterías propuestas.

3. Leer los resultados: la primera tarjeta es la cafetería elegida (*Tu selección*) y las tres siguientes son las más similares, cada una con su porcentaje de similitud.

4. Ubicar las cuatro en el mapa, donde la referencia aparece en rojo y las demás en gris.

5. Para explorar otra, elegir una nueva cafetería o quitar la selección con la cruz del buscador.

Función 2: buscar por las características que se desean.

1. En la portada, elegir *Usuario de Cafeterías* y, en la página de recomendación, elegir *Por características*.

2. Pulsar una o más de las 20 características, por ejemplo *ambiente tranquilo* y *para trabajar*.

3. Los resultados se actualizan con cada pulsación, sin botón de búsqueda: las diez cafeterías cuyas reseñas más se parecen a la combinación elegida aparecen como tarjetas y como puntos en el mapa.

4. Para empezar de nuevo, usar el botón *Limpiar*.

Las Figuras 14, 15 y 16 muestran las pantallas de la aplicación.

7.4. Pruebas realizadas

Las pruebas se hicieron en el equipo de desarrollo, con el servicio y la interfaz ejecutándose de forma local, por lo que los tiempos no incluyen la red; en la versión desplegada (Sección 7.5) pueden ser mayores.

- **Funcionamiento del modelo.** El *notebook* de modelado incluye una prueba de ida y vuelta del archivo del modelo, que se abre en un proceso limpio con solo `joblib` y `numpy`, y una prueba de contrato con el servicio, que verifica que las respuestas tengan los campos que espera la interfaz. El servicio responde con los códigos de error esperados cuando la cafetería no existe (404), la solicitud es inválida (422) o el modelo de texto no está disponible (503).

- **Tiempos de respuesta del servicio.** La Tabla 9 reporta las medianas y los percentiles 95 de cada consulta. La recomendación por cafetería tarda una mediana de 6 ms y la de características, que convierte el texto a vector, 56 ms.

- **Tiempos de la interfaz.** Se midió el tiempo desde que la persona pulsa una cafetería del buscador o una característica hasta que las tarjetas nuevas están en pantalla, con 15 repeticiones de cada una. La mediana es de 35 ms en la Función 1 (percentil 95 de 45 ms) y de 91 ms en la Función 2 (percentil 95 de 117 ms).



Figura 14. Portada de la aplicación, con la selección del tipo de usuario. Fuente: captura de la aplicación Locus.

- **Pasos por tarea.** En la Función 1 se llega al resultado con una pulsación si se usa una cafetería propuesta y con dos acciones (escribir y elegir) si se usa el buscador. En la Función 2 basta una pulsación por característica, sin botón de búsqueda.
- **Pantallas.** La aplicación se revisó en un navegador con anchos de ventana de 500 a 1,920 píxeles. En una ventana de 1,366 por 650 píxeles, la portada muestra completas las tarjetas de selección de usuario sin desplazarse.
- **Accesibilidad básica.** El buscador funciona como lista desplegable con navegación por teclado (flechas, Enter y Escape), los botones y el mapa tienen etiquetas para lectores de pantalla, las características seleccionadas se indican con un atributo de estado y las animaciones se desactivan si el sistema operativo lo solicita.

No se realizaron pruebas de uso con personas; por esta razón el documento describe el diseño y lo medido, pero no afirma que la aplicación resulte intuitiva para quienes la usan. Esta prueba se propone como siguiente paso (Sección 9.1).

7.5. Despliegue

La aplicación web se compone de dos servicios independientes desplegados en la nube: el servicio de datos (*backend*) en Railway y la interfaz de usuario (*frontend*) en Vercel. Ambos servicios se conectan a un repositorio privado de GitHub creado específicamente para

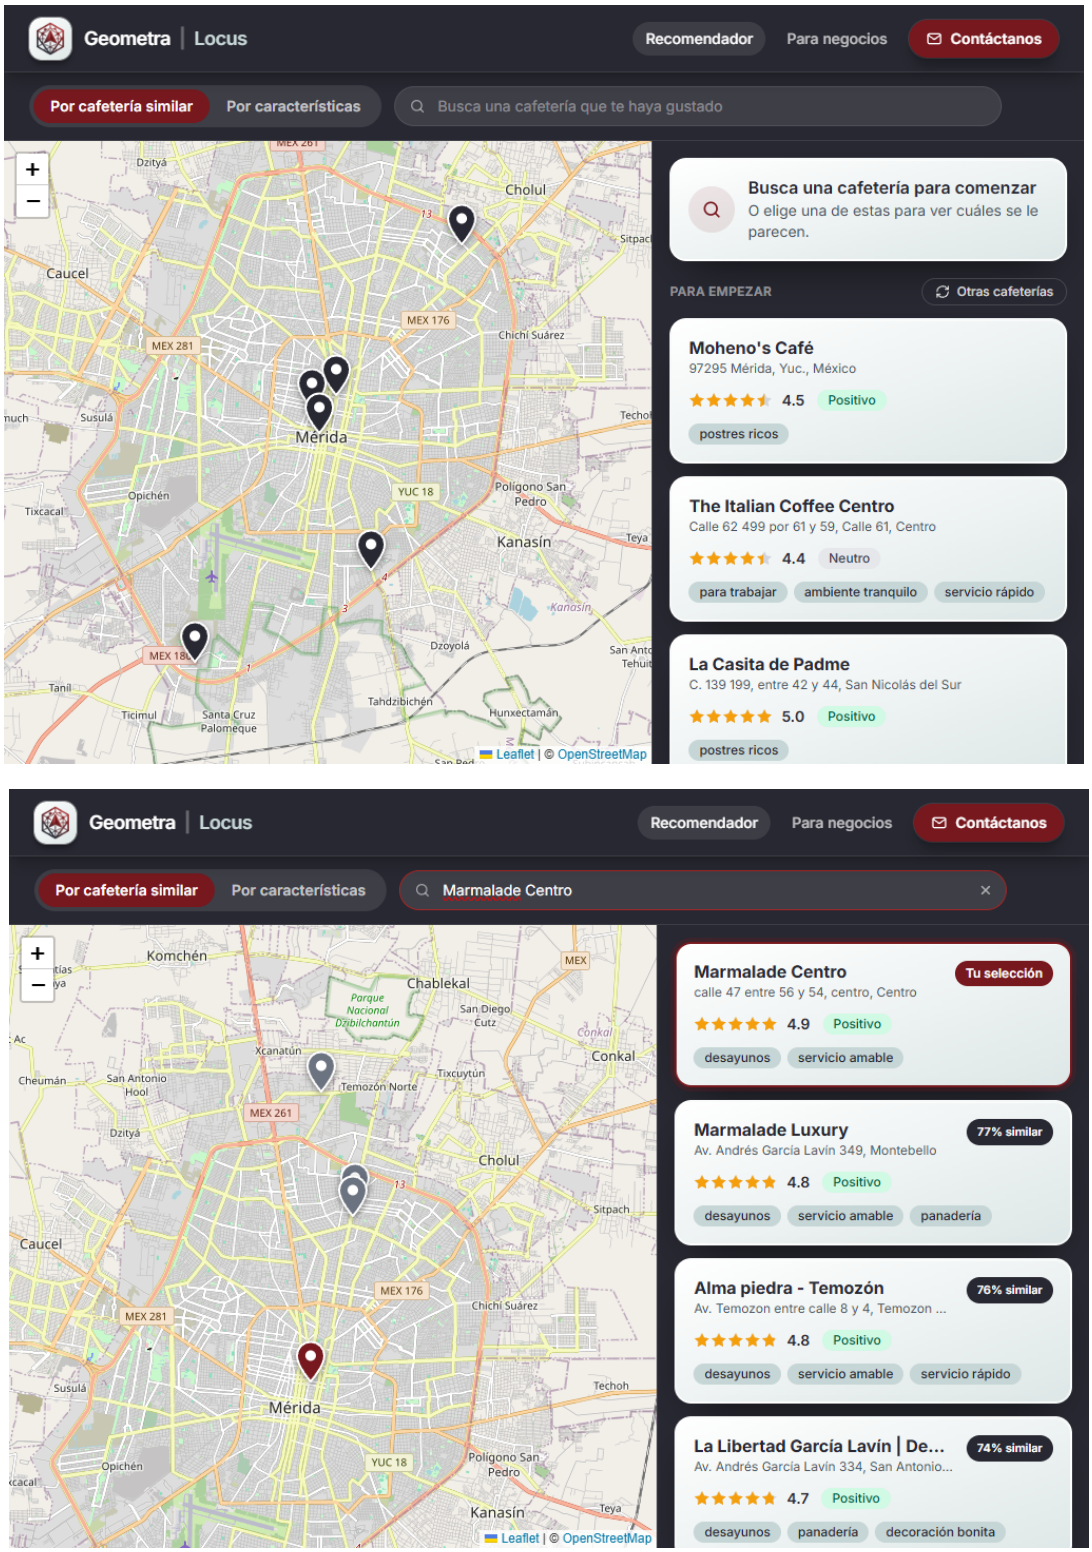


Figura 15. Función 1 (*Por cafetería similar*): estado inicial, con seis cafeterías propuestas (arriba), y resultado para Marmalade Centro (abajo). Fuente: captura de la aplicación Locus.

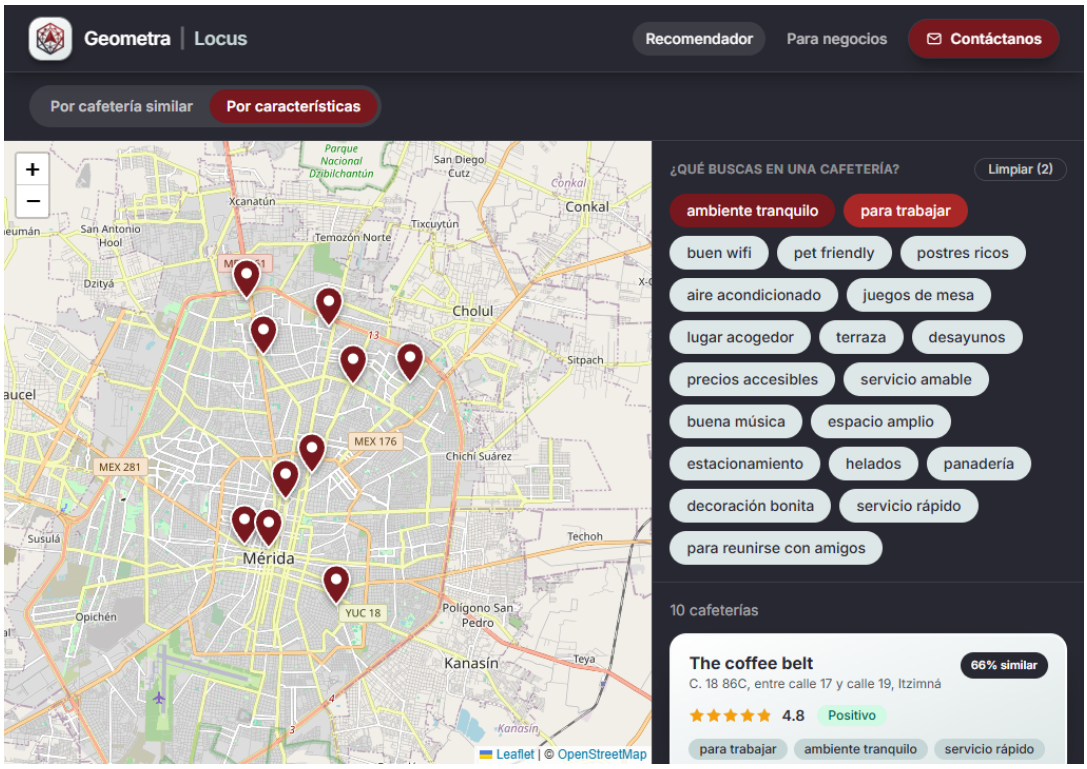


Figura 16. Función 2 (*Por características*) con las características "ambiente tranquilo" y "para trabajar" elegidas. Fuente: captura de la aplicación Locus.

Tabla 9. Tiempos de respuesta del servicio en el equipo de desarrollo. Las consultas de recomendación se repitieron 60 veces con cafeterías y combinaciones de características elegidas al azar, y `/cafes` y `/tags` 20 veces. Fuente: elaboración propia.

Consulta	Mediana (ms)	Percentil 95 (ms)	Máximo (ms)
`/recommend`, modo `place`	6	22	31
`/recommend`, modo `text`	56	85	215
`/cafes` (316 KB)	35	51	55
`/tags`	5	28	29

este proyecto, llamado `geometra-locus`, y se actualizan automáticamente con cada envío de cambios (*push*) a la rama principal, lo que simplifica el ciclo de actualización durante el desarrollo.

El servicio de datos se configuró con `app/backend/` como directorio raíz. El comando de inicio es `uvicorn main:app --host 0.0.0.0 --port $PORT`, donde Railway inyecta la variable `PORT` (8080) al arrancar el contenedor. Se usó un plan con hasta 8 GB de RAM, porque la biblioteca `sentence-transformers` con PyTorch ocupa aproximadamente 1.5 GB al cargar el modelo de texto `paraphrase-multilingual-MiniLM-L12-v2`, más que el límite del plan gratuito (512 MB). El modelo se precarga al arrancar el servidor para que la primera solicitud del modo de búsqueda por características no incurra en la latencia de carga. Las

variables de entorno configuradas en Railway son `CORS_ORIGINS`, que contiene la URL de la interfaz para permitir las peticiones entre dominios, y `HF_TOKEN`, que autentica las descargas desde Hugging Face Hub y evita los límites de tasa para cuentas anónimas.

La interfaz se configuró con `app/frontend/` como directorio raíz en Vercel. Vercel detecta automáticamente la herramienta de construcción Vite, y el paquete de la aplicación (*bundle*) se genera con `npm run build`. Se añadió un archivo `vercel.json` con una regla de reescritura que redirige todas las rutas a `index.html`. Esta regla es necesaria porque Vue Router opera en modo *history*, y sin ella las rutas distintas a la raíz devuelven un error 404 al recargarse. La variable de entorno `VITE_API_URL` apunta a la URL pública del servicio de datos en Railway; al ser una variable de Vite, se incrusta en el paquete durante la compilación, por lo que cualquier cambio en su valor requiere volver a desplegar la interfaz para que tenga efecto.

La aplicación se encuentra disponible en https://geometra-locus.vercel.app.

8. Estrategia

Esta sección define para quiénes se diseñó el modelo, qué acciones concretas se desprenden de sus resultados y qué tanto la aplicación atiende las necesidades de esas personas.

8.1. Descripción de usuarios

El proyecto reconoce dos perfiles con necesidades distintas:

- **Persona usuaria final.** Quien vive, visita o trabaja en Mérida, incluidos los residentes, los turistas y las personas que trabajan de forma remota (Sección 2), y elige dónde tomar un café. Necesita encontrar opciones sin revisar cientos de reseñas, confiar en un resultado que no dependa solo de la calificación (que distingue poco entre lugares, Sección 3.2), ubicar el lugar en el mapa y entender por qué se le propone. Puede encontrarse en dos situaciones: conoce una cafetería que le gustó y busca otras parecidas, o sabe qué experiencia busca (trabajar con calma, desayunar, tomar un postre) pero no dónde encontrarla. La primera se atiende con la Función 1 y la segunda con la Función 2.

- **Persona dueña o encargada de una cafetería.** Necesita conocer lo que dicen sus clientes y con qué establecimientos compite en experiencia. Para este perfil el proyecto no construyó una herramienta: la página de la aplicación destinada a negocios se encuentra en desarrollo y solo invita a contactar al equipo. Los resultados del proyecto sí permiten formular acciones (Sección 8.2), y el mismo modelo, aplicado a una cafetería propia, podría identificar a sus competidoras más parecidas en una etapa posterior.

8.2. Accionables

Esta subsección traduce los hallazgos del documento en recomendaciones prácticas, llamadas accionables: qué puede hacer cada actor a partir de lo que se encontró en los datos. Se dirigen a tres destinatarios: las personas que buscan una cafetería, los dueños de cafeterías y el propio equipo de Geometra. Solo se incluye una recomendación si cumple dos condiciones: que alguien concreto pueda llevarla a cabo y que se apoye en un resultado medido en este

trabajo. Por eso se dejan fuera las que requerirían datos que no se tienen, como cuántas personas visitan cada cafetería. La Tabla 10 presenta cada accionable junto con el dato que lo respalda y la sección donde se encuentra.

Tabla 10. Accionables y su fundamento. La última columna indica la sección del documento donde se presenta el dato. Fuente: elaboración propia.

Accionable	Fundamento	Sección
Para la persona que busca una cafetería		
Elegir una cafetería por el tipo de experiencia que ofrece y no por su calificación.	Casi todas las calificaciones son altas, por lo que distinguen poco entre lugares: 73.8 % de los lugares tiene 4.5 estrellas o más, 37.0 % tiene exactamente 5.0 y 77.2 % de las reseñas son de cinco estrellas.	3.2, 3.3
Revisar cuántas reseñas respaldan una calificación antes de confiar en ella.	Las calificaciones perfectas suelen venir de pocas opiniones: en la cuarta parte de los lugares con menos reseñas la calificación mediana es 5.0, y en la cuarta parte con más reseñas es 4.6. Por esto la aplicación señala como de baja confianza a las 340 cafeterías, de 1,111, que tienen menos de cinco reseñas con texto.	3.2, 5.4
Para dueños de cafeterías (cuando exista la herramienta para negocios)		
Dar prioridad a la atención y a los tiempos de espera.	Las quejas más frecuentes en las reseñas negativas (una o dos estrellas) se refieren al servicio. Los pares de palabras que más se repiten son *pésimo servicio* (109 veces), *mal servicio* (60), *mala experiencia* (51), *atención cliente* (44) y *media hora* (21), este último asociado a esperas largas.	3.3
Leer lo que dicen las reseñas y no fijarse solo en las estrellas.	En 38 de los 771 lugares con al menos cinco reseñas con texto, el tono de las reseñas, medido por el modelo de sentimiento en una escala de 1 a 5, queda más de una estrella por debajo de la calificación en Google. Por ejemplo, dos sucursales de Starbucks tienen 4.5 y 4.4 estrellas, pero el tono de sus reseñas equivale a 2.5 y 2.9.	3.3
Dar a conocer los servicios con que cuenta el negocio, como wifi, terraza o admisión de mascotas.	El modelo solo sabe lo que dicen las reseñas, y estos servicios casi no se mencionan: solo 22 cafeterías tienen dos o más reseñas que hablan del wifi, 28 de las mascotas y 64 de la terraza. Por eso la búsqueda de estas características tiene una precisión de apenas 0.00 a 0.20.	5.5, 5.7
Pedir a los clientes que dejen reseñas escritas.	Las cafeterías con menos de cinco reseñas con texto casi nunca aparecen entre los primeros resultados, y las 508 que no tienen ninguna no se recomiendan.	5.4, 5.7

Accionable	Fundamento	Sección
Para Geometra (producto y datos)		
Ampliar y actualizar la base de reseñas.	Se extrajeron como máximo 25 reseñas por lugar; 340 cafeterías tienen menos de cinco con texto y 508 no tienen ninguna.	4.4, 5.7
Mejorar la búsqueda de las características que se mencionan poco.	Seis de las 20 características tienen una precisión de 0.00 a 0.30 en los diez primeros resultados. En una prueba preliminar se logró mejorar algunas, pero a cambio bajó la precisión promedio del conjunto.	5.7
En un futuro análisis para negocios, usar la cantidad de cafeterías por zona solo como contexto.	403 de las 541 AGEB urbanas tienen al menos una cafetería, y las diez con más cafeterías concentran 13.2 % de los lugares. En el DENUE, el código de cafeterías (722515) creció 9.9 % entre 2024 y 2026, frente a 4.7 % del resto de los servicios de alimentos y bebidas. Estas cifras indican cuánta oferta hay, pero no cuántos clientes, por lo que no bastan para decidir dónde abrir un negocio.	3, 3.2

8.3. Usabilidad del modelo

La usabilidad se evaluó con lo que puede medirse sin usuarios (Sección 7.4). Los criterios y la manera en que la aplicación los atiende son los siguientes:

- **Pocos pasos.** La Función 1 se resuelve con una o dos acciones y la Función 2 con una pulsación por característica, sin botón de búsqueda.
- **Respuesta inmediata.** En el equipo de desarrollo, las tarjetas nuevas aparecen en una mediana de 35 ms (Función 1) y 91 ms (Función 2) después de la pulsación.
- **Vocabulario cotidiano.** Las 20 características son frases de uso común (por ejemplo, *ambiente tranquilo* o *para trabajar*) y no requieren conocimientos técnicos.
- **Resultados que se pueden interpretar.** Cada tarjeta muestra la calificación, el sentimiento, los atributos, la ubicación y, cuando corresponde, la etiqueta “Pocas reseñas”. El porcentaje de similitud permite comparar los resultados entre sí.
- **Adaptación a distintas pantallas y accesibilidad básica.** Se describen en la Sección 7.4.

La principal limitación es que no se hicieron pruebas con personas. Sin ellas, no se puede afirmar que la aplicación sea intuitiva ni conocer los errores en que incurren quienes la usan por primera vez. Una prueba sencilla, con pocas personas y tareas definidas, se plantea como siguiente paso.

8.4. Alcance del negocio

Geometra contempla dos líneas: una aplicación de recomendación para la persona usuaria, que es la que se presenta en este documento, y, en una etapa posterior, un servicio de análisis para dueños de cafeterías. El proyecto no estima ingresos ni demanda: los datos disponibles describen la oferta y las reseñas, y no el comportamiento de quienes buscan cafeterías. Por esta razón, cualquier propuesta comercial requeriría validarse antes con personas usuarias y con negocios.

9. Conclusiones

Se construyó un recomendador de cafeterías para Mérida que se basa en lo que expresan sus clientes en las reseñas. Para ello se reunieron 1,619 lugares con Google Places y 17,422 reseñas de Google Maps, se analizaron los datos y se desarrolló un modelo, sustentado en un modelo de lenguaje preentrenado y en la similitud del coseno, que ofrece dos funciones: encontrar las cafeterías más similares a una dada y encontrar las que mejor responden a una combinación de características. El modelo se puso a disposición mediante una aplicación web con mapa. Los hallazgos principales son los siguientes:

- **La calificación distingue poco entre cafeterías.** 73.8 % de los lugares tiene 4.5 o más y 77.2 % de las reseñas son de cinco estrellas, por lo que ordenar por calificación aporta poca información y se justifica recomendar por el contenido de las reseñas.
- **El texto aporta información que la calificación no captura.** El sentimiento promedio de las reseñas se relaciona con la calificación (correlación de 0.77), pero en algunos lugares se separa de ella, como en las 46 sucursales de Starbucks, The Italian Coffee y Dunkin', cuyo sentimiento medio es de 3.25 estrellas frente a 4.41 del resto.
- **El parecido entre reseñas funciona para los temas frecuentes.** La búsqueda por características alcanza una precisión de 0.61 en los diez primeros resultados frente a 0.14 de un orden al azar, y 14 de las 20 características llegan a 0.5 o más. En los temas poco frecuentes, como el wifi, la precisión es baja.
- **Las decisiones de diseño se sustentaron en datos.** Centrar los vectores corrigió la escala de la Función 1, la plantilla de la consulta elevó la precisión de la Función 2 de 0.38 a 0.61 y la ponderación por número de reseñas evitó que las cafeterías con pocas reseñas ocuparan los primeros lugares.

El desempeño se considera satisfactorio para los temas frecuentes y limitado para los poco frecuentes. La evaluación tiene un alcance acotado: mide menciones de palabras y no la satisfacción de las personas, y no se realizaron pruebas con usuarios, por lo que todavía no es posible afirmar la utilidad de la aplicación en el uso real. Adicionalmente, el modelo solo puede recomendar las 1,111 cafeterías con reseñas con texto, y las que tienen menos de cinco reseñas con texto casi no aparecen en los resultados. En cuanto a la estrategia, los resultados sustentan acciones para la persona usuaria, para los dueños de cafeterías y para el propio producto (Sección 8.2), aunque no permiten estimar la demanda ni los ingresos de un servicio de este tipo.

9.1. Siguientes pasos

- **Probar la aplicación con personas.** Una prueba con pocas personas, con tareas definidas (encontrar una cafetería parecida a una conocida y encontrar un lugar para trabajar), en la que se registren los tiempos, los errores y las dudas, para sustentar la usabilidad.
- **Mejorar las características poco frecuentes.** Comparar la agregación por reseña, que en una prueba exploratoria preliminar mejoró algunas de ellas, con el promedio de *embeddings* actual, y probar otros modelos de *embeddings* multilingües.
- **Ampliar los datos.** Extraer más de 25 reseñas por lugar y actualizarlas de forma periódica, y agregar la colonia de cada cafetería.
- **Explorar el agrupamiento.** Aplicar un algoritmo de *clustering* para describir tipos de cafeterías, lo que en este trabajo no fue necesario para recomendar.
- **Desarrollar la línea para negocios.** Analizar el posicionamiento de una cafetería frente a sus competidoras más parecidas y las tendencias de sus reseñas, apoyándose en el mismo modelo.

Referencias

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (Vol. 1, pp. 4171-4186). Association for Computational Linguistics.

Google. (s.f.). *Places API. Google Maps Platform*. Recuperado el 8 de septiembre de 2026, de https://developers.google.com/maps/documentation/places/web-service

Instituto Nacional de Estadística y Geografía. (s.f.). *Directorio Estadístico Nacional de Unidades Económicas (DENUE)*. Recuperado el 8 de septiembre de 2026, de https://www.inegi.org.mx/app/mapa/denue/

Instituto Nacional de Estadística y Geografía. (2023). *Manual de cartografía. Censo de Población y Vivienda 2020*. https://www.inegi.org.mx/contenidos/productos/prod_serv/contenidos/espanol/bvinegi/productos/nueva_estruc/889463906995.pdf

Instituto Nacional de Estadística y Geografía. (2024). *Marco Geoestadístico, versión 2024*. Recuperado el 9 de septiembre de 2026, de https://www.inegi.org.mx/temas/mg/

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

NLP Town. (s.f.). *bert-base-multilingual-uncased-sentiment* [Modelo]. Hugging Face. Recuperado el 25 de septiembre de 2026, de https://huggingface.co/nlptown/bert-base-multilingual-uncased-sentiment

Radovanović, M., Nanopoulos, A., & Ivanović, M. (2010). Hubs in space: Popular nearest neighbors in high-dimensional data. *Journal of Machine Learning Research, 11*, 2487-2531.

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)* (pp. 3982-3992). Association for Computational Linguistics.

Reimers, N., & Gurevych, I. (2020). Making monolingual sentence embeddings multilingual using knowledge distillation. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 4512-4525). Association for Computational Linguistics.

Ricci, F., Rokach, L., & Shapira, B. (2015). Recommender systems: Introduction and challenges. En F. Ricci, L. Rokach & B. Shapira (Eds.), *Recommender Systems Handbook* (2.ª ed., pp. 1-34). Springer.

Sentence-Transformers. (s.f.). *paraphrase-multilingual-MiniLM-L12-v2* [Modelo]. Hugging Face. Recuperado el 25 de septiembre de 2026, de https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research, 9*, 2579-2605.

Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. En *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)* (pp. 5776-5788). Curran Associates.

Anexos

Anexo A. Diccionario de variables

Se describen las variables de las dos bases que se generan en el análisis exploratorio (Sección 4) y que alimentan el modelo: la tabla de lugares (`cafeterias_features.csv`, 1,619 filas y 24 columnas) y la tabla de reseñas (`reviews_features.csv`, 17,422 filas y 13 columnas). Las cifras entre paréntesis son las de la versión final de las bases.

Tabla 11. Variables de la tabla de lugares (`cafeterias_features.csv`). Fuente: elaboración propia con datos de Google Places, del Marco Geoestadístico y de las reseñas de Google Maps.

Variable	Tipo	Descripción
`place_id`	texto	Identificador único del lugar en Google Places.
`celda_id`	entero	Celda de la malla de búsqueda en la que se encontró el lugar.
`nombre_google`	texto	Nombre del lugar en Google Maps.
`direccion_google`	texto	Dirección completa que reporta Google.
`lat_google`	decimal	Latitud del lugar, en grados (EPSG:4326).
`lon_google`	decimal	Longitud del lugar, en grados (EPSG:4326).
`primary_type`	categoría	Tipo principal del lugar según Google, por ejemplo `coffee_shop` o `cafe`.
`types`	texto	Lista de todos los tipos que Google asigna al lugar, separados por comas.
`rating`	decimal	Calificación promedio en Google, de 1 a 5. Nulo si el lugar no tiene reseñas registradas.
`n_resenas`	entero	Número total de reseñas que Google registra para el lugar. Nulo si no tiene.
`business_status`	categoría	Estatus operativo. Todos los lugares de la base son `OPERATIONAL`.
`price_level`	categoría	Nivel de precio que reporta Google (económico, moderado, caro o muy caro). Nulo en 903 lugares.
`resumen_editorial`	texto	Descripción breve que Google publica del lugar, en inglés. Solo 32 lugares la tienen.
`google_maps_uri`	texto	Enlace al lugar en Google Maps.
`google_maps_links`	texto	Enlaces de Google Maps del lugar en formato JSON (cómo llegar, lugar, escribir una reseña, reseñas y fotos).
`flag_comentario`	booleano	Vale 1 si se extrajeron reseñas del lugar (1,223 lugares) y 0 si no (396).
`cvegeo`	texto	Clave geoestadística de 13 caracteres de la AGEB urbana que contiene al lugar. Nulo en los 16 lugares que quedan fuera de las AGEB.

Variable	Tipo	Descripción
`n_resenas_scrapeadas`	entero	Número de reseñas extraídas del lugar (0 si ninguna; máximo 25).
`rating_resenas_promedio`	decimal	Calificación promedio de las reseñas extraídas. Nulo si no hay.
`sentimiento_promedio`	decimal	Promedio de las estrellas que el modelo de sentimiento asigna a las reseñas con texto del lugar. Nulo si no hay reseñas con texto.
`sentimiento_std`	decimal	Desviación estándar de esas estrellas. Nulo si el lugar tiene una sola reseña con texto o ninguna.
`n_resenas_con_texto`	entero	Número de reseñas extraídas que incluyen texto.
`apto_recomendador`	booleano	Verdadero si el lugar tiene al menos una reseña con texto. Son los candidatos a ser recomendados (1,111).
`baja_confianza`	booleano	Verdadero si el lugar es apto y tiene menos de cinco reseñas con texto (340).

Tabla 12. Variables de la tabla de reseñas (`reviews_features.csv`). Fuente: elaboración propia con reseñas de Google Maps.

Variable	Tipo	Descripción
`place_id`	texto	Identificador del lugar al que pertenece la reseña.
`place_name`	texto	Nombre del lugar.
`reviewer_name`	texto	Nombre de la persona autora tal como aparece en Google Maps. No interviene en el análisis ni en el modelo.
`rating`	entero	Calificación de la reseña, de 1 a 5 estrellas.
`relative_date`	texto	Fecha relativa que muestra Google Maps, por ejemplo “Hace 2 meses”. No interviene en el análisis ni en el modelo.
`review_text`	texto	Texto original de la reseña. Nulo si solo tiene calificación.
`scraped_at`	fecha y hora	Momento de la extracción de la reseña (UTC).
`review_id`	entero	Identificador de la reseña, asignado en la extracción.
`longitud_texto`	entero	Número de caracteres del texto original.

Variable	Tipo	Descripción
`sentiment_stars`	entero	Estrellas (de 1 a 5) que el modelo de sentimiento asigna al texto. Nulo si no hay texto.
`sentiment_score`	decimal	Probabilidad que el modelo de sentimiento asigna a la clase elegida; indica su confianza en la predicción.
`review_text_limpio`	texto	Texto con los espacios y saltos de línea normalizados. Es el que se convierte en vector.
`sin_texto`	booleano	Verdadero si la reseña solo tiene calificación (1,737 reseñas).

Anexo B. Resultados de la Función 2 por consulta

La Tabla 13 presenta, para cada una de las 16 consultas de evaluación, la tasa base, la precisión en los cinco y en los diez primeros resultados con la ponderación que usa la aplicación, el *lift*, la precisión en los diez primeros sin ponderar y el número de cafeterías de baja confianza que ocuparían esos diez lugares sin ponderar. Con la ponderación, ninguna consulta incluye cafeterías de baja confianza entre sus diez primeros resultados.

Tabla 13. Resultados de la Función 2 en las 16 consultas de evaluación. En las dos últimas columnas, "sin pond." es sin ponderar por número de reseñas y "baja conf." es de baja confianza. Fuente: elaboración propia.

Consulta	Tasa base	P@5	P@10	*Lift*	P@10 sin pond.	Baja conf. sin pond.
ambiente tranquilo	0.21	0.80	0.70	3.27	0.50	5
para trabajar	0.10	0.60	0.70	7.13	0.50	3
buen wifi	0.02	0.00	0.00	0.00	0.00	2
pet friendly	0.03	0.20	0.20	7.94	0.20	1
postres ricos	0.20	1.00	1.00	5.00	0.90	1
aire acondicionado	0.09	0.80	0.70	7.48	0.40	5
juegos de mesa	0.04	1.00	0.90	25.00	0.80	1
terraza	0.06	0.20	0.20	3.47	0.10	6
desayunos	0.19	1.00	1.00	5.17	0.60	5
lugar acogedor	0.17	0.40	0.30	1.79	0.30	4
espacio amplio	0.04	0.00	0.10	2.58	0.00	6
buena música	0.09	0.80	0.70	7.78	0.50	4
ambiente tranquilo para trabajar	0.27	1.00	1.00	3.67	0.70	4
ambiente tranquilo buen wifi para trabajar	0.28	0.80	0.90	3.24	0.60	4
pet friendly terraza	0.08	0.40	0.30	3.70	0.20	3
postres ricos desayunos	0.35	1.00	1.00	2.89	0.70	3